

IFG - Câmpus Anápolis
Ciência da Computação

Filipe Divino Silva de Azevedo
Ismael Vitor Rodrigues Pimentel

Mineração de Dados
SPIDER 2.0

Anápolis - GO
2026

Filipe Divino Silva de Azevedo
Ismael Vitor Rodrigues Pimentel

Mineração de Dados
SPIDER 2.0

Trabalho apresentado à disciplina de Mineração
de Dados como requisito parcial de avaliação do
período letivo 2026.1.

IFG - Câmpus Anápolis
Ciência da Computação

Orientador: Sérgio Daniel Carvalho Canuto

Anápolis - GO
2026

Resumo

Este relatório descreve a aplicação de técnicas de mineração de dados em dois bancos da coleção Spider 2.0: a base F1, ligada ao automobilismo, e a base *movie_recomm*, voltada ao domínio de filmes e sistemas de recomendação. O trabalho incluiu a compreensão das estruturas relacionais, a preparação e verificação da qualidade dos dados, a análise exploratória, a definição das transações e a extração de regras de associação. Na F1, cada transação correspondeu ao resultado de um piloto em uma corrida e reuniu sua faixa de largada, o resultado obtido e a equipe. O Apriori foi executado na série completa e nos períodos 1950–1959 e 2014–2024, resultando, respectivamente, em 9, 17 e 21 regras com suporte mínimo de 2% e confiança mínima de 60%. A revisão pelo lift mostrou que algumas regras dos anos 1950, embora tivessem confiança alta, não representavam associação positiva e foram retiradas da seleção final. Na base de filmes, 3.649 produções foram representadas por seus gêneros, período de lançamento, faixa de avaliação e popularidade. O FP-Growth encontrou 501 itemsets frequentes e 121 regras após os filtros iniciais; depois da análise de lift, redundância e obviedade, 30 regras foram mantidas. A comparação entre os bancos mostra que a unidade transacional, o período histórico, o desbalanceamento e o significado dos atributos influenciam diretamente os padrões encontrados. Ao final, foram organizadas 45 perguntas e respostas interpretativas, sempre tratando as regras como coocorrências, e não como relações de causa e efeito.

Palavras-chave: mineração de dados; regras de associação; Apriori; FP-Growth; Fórmula 1; MovieLens.

Abstract

This report describes the application of data-mining techniques to two Spider 2.0 databases: F1, from the motorsport domain, and *movie_recomm*, from the movie and recommender-systems domain. The study covered structural understanding, data preparation and quality checking, exploratory analysis, transaction design, and association-rule extraction. In F1, each transaction represented a driver's result in a race and combined starting-grid range, result category, and team. Apriori was applied to the complete series and to the 1950–1959 and 2014–2024 periods, yielding 9, 17, and 21 rules, respectively, with 2% minimum support and 60% minimum confidence. Lift-based review showed that some early-period rules, despite their confidence, did not represent positive associations and were excluded from the final selection. In the movie database, 3,649 productions were represented by genres, release period, rating range, and popularity. FP-Growth produced 501 frequent itemsets and 121 rules after the initial filters; 30 rules were retained after checking lift, redundancy, and obviousness. The comparison indicates that transaction definition, historical period, imbalance, and attribute meaning directly affect the patterns found. In total, 45 interpretive questions and answers were organized, with the results treated as co-occurrences rather than causal relationships.

Keywords: data mining; association rules; Apriori; FP-Growth; Formula 1; MovieLens.

Lista de ilustrações

Figura 1 – Evolução da Fórmula 1 ao longo das temporadas	13
Figura 2 – Grandes Prêmios disputados por equipe	14
Figura 3 – Taxa de vitória por equipe	14
Figura 4 – Nacionalidade dos pilotos vencedores	15
Figura 5 – Equipe com maior número de vitórias em cada década	16
Figura 6 – Distribuição da pontuação obtida pelos pilotos	17
Figura 7 – Boxplot da posição de largada	17
Figura 8 – Boxplot da pontuação obtida	18
Figura 9 – Matriz de correlação das variáveis numéricas da base F1	19
Figura 10 – Distribuição das notas atribuídas pelos usuários	32
Figura 11 – Distribuição das médias de avaliação dos filmes	32
Figura 12 – Distribuição da quantidade de avaliações entre os filmes preparados	33
Figura 13 – Boxplot da média de avaliações entre os filmes preparados	34
Figura 14 – Boxplot da quantidade de avaliações entre os filmes preparados	34
Figura 15 – Gêneros mais frequentes entre os filmes preparados	35
Figura 16 – Quantidade de filmes por período de lançamento	36
Figura 17 – Matriz de correlação das variáveis numéricas entre os filmes preparados . . .	37

Lista de tabelas

Tabela 1 – Tabelas principais da base F1	11
Tabela 2 – Resumo dos experimentos de regras na base F1	20
Tabela 3 – Regras da base completa da Fórmula 1 (1950–2024)	20
Tabela 4 – Regras representativas da era híbrida (2014–2024)	21
Tabela 5 – Regras positivas das primeiras temporadas (1950–1959)	22
Tabela 6 – Auditoria crítica das regras da base F1	23
Tabela 7 – Perguntas e respostas derivadas das regras da base F1	24
Tabela 8 – Tabelas principais da base <i>movie_recomm</i>	27
Tabela 9 – Relacionamentos relevantes entre as tabelas	28
Tabela 10 – Atributos selecionados e suas finalidades	29
Tabela 11 – Resumo da qualidade dos dados	30
Tabela 12 – Variáveis derivadas e critérios de discretização	30
Tabela 13 – Estatísticas descritivas das variáveis principais	31
Tabela 14 – Possíveis valores extremos segundo o intervalo interquartil	33
Tabela 15 – Gêneros mais frequentes entre os filmes preparados	35
Tabela 16 – Distribuição das faixas discretizadas	36
Tabela 17 – Parâmetros utilizados na extração das regras	39
Tabela 18 – Resultados do processo de extração e filtragem	39
Tabela 19 – Exemplos de regras auditadas e decisões de filtragem	41
Tabela 20 – Discussão crítica de regras representativas	41
Tabela 21 – Perguntas e respostas derivadas das regras de associação	43
Tabela 22 – Comparação dos experimentos de mineração	49

Lista de abreviaturas e siglas

CSV	<i>Comma-Separated Values</i>
EDA	Análise Exploratória de Dados
F1	Fórmula 1
FP-Growth	<i>Frequent Pattern Growth</i>
IQR	Intervalo interquartil

Sumário

1	Introdução	9
I	Base de Fórmula 1	10
2	Compreensão da base F1	11
2.1	Nome e domínio	11
2.2	Estrutura da base	11
3	Preparação dos dados da base F1	12
3.1	Seleção e qualidade dos dados	12
3.2	Discretização e transações	12
4	Caracterização exploratória da base F1	13
4.1	Evolução histórica	13
4.2	Participação e desempenho das equipes	13
4.3	Nacionalidades e domínio por década	15
4.4	Distribuição, correlação e valores extremos	16
5	Modelagem e extração das regras da base F1	20
5.1	Estratégia e parâmetros	20
5.2	Base completa: 1950–2024	20
5.3	Era híbrida: 2014–2024	21
5.4	Primeiras temporadas: 1950–1959	22
6	Análise crítica e perguntas da base F1	23
6.1	Auditoria das regras	23
6.2	Perguntas e respostas	23
II	Base <i>Movie Recommendation Database</i>	26
7	Compreensão da base escolhida	27
7.1	Nome e domínio da base	27
7.2	Tabelas analisadas	27
7.3	Tipos de atributos	27
7.4	Relacionamentos relevantes	28
7.5	Justificativa da seleção	28
8	Preparação dos dados	29
8.1	Seleção das tabelas e dos atributos	29
8.2	Qualidade e integridade dos dados	29
8.3	Agregação e criação de variáveis	30
9	Caracterização exploratória dos dados	31

9.1	Distribuição das avaliações	31
9.2	Popularidade e valores extremos	32
9.3	Frequência dos gêneros e dos períodos	35
9.4	Correlações	36
10	Modelagem da estratégia para extração de regras	38
11	Extração das regras de associação	39
12	Análise crítica das regras relevantes	41
12.1	Regras óbvias, redundantes ou pouco úteis	41
12.2	Discussão de regras representativas	41
13	Perguntas e respostas derivadas das regras	43
14	Síntese da base <i>movie_recomm</i>	48
15	Comparação entre as bases	49
16	Conclusão	50
	 Referências	 51

1 Introdução

Este trabalho analisa dois bancos relacionais da coleção Spider 2.0: F1 e *movie_recomm*. A escolha de domínios diferentes foi útil para observar como uma mesma técnica se comporta em contextos bastante distintos. A base F1 registra a trajetória histórica do Campeonato Mundial de Fórmula 1, enquanto a base *movie_recomm* reúne filmes e avaliações feitas por usuários do MovieLens.

O estudo foi organizado em etapas: primeiro, foi necessário entender a estrutura de cada banco; em seguida, os dados foram preparados e caracterizados; depois, foram definidas unidades transacionais adequadas a cada domínio; por fim, as regras de associação foram extraídas e interpretadas. A comparação entre as duas bases permite discutir, de maneira mais concreta, como o significado dos atributos, o volume dos dados, a discretização e o desbalanceamento influenciam os resultados.

Na F1 foi utilizado o algoritmo Apriori, desenvolvido para identificar conjuntos frequentes e gerar regras a partir de suporte e confiança (AGRAWAL; SRIKANT, 1994). Na base de filmes foi aplicado o FP-Growth, que encontra padrões frequentes sem precisar gerar explicitamente todos os candidatos do Apriori (HAN; PEI; YIN, 2000). As tabelas MovieLens consideradas neste trabalho são descritas por Harper e Konstan (2015).

O enunciado solicita pelo menos 30 perguntas e respostas por grupo. Neste relatório foram incluídas 15 perguntas derivadas da base F1 e 30 da base *movie_recomm*, totalizando 45. A distribuição não foi feita de maneira uniforme porque, após a auditoria das regras da F1, várias associações adicionais se mostraram redundantes, excessivamente óbvias ou pouco relevantes pelo lift.

Parte I

Base de Fórmula 1

2 Compreensão da base F1

2.1 Nome e domínio

A base F1 reúne registros históricos do Campeonato Mundial de Fórmula 1. Seu conteúdo permite acompanhar diferentes aspectos da competição, como pilotos, equipes, circuitos, corridas, classificações, resultados, tempos de volta, paradas nos boxes e temporadas.

2.2 Estrutura da base

O banco contém 45 tabelas quando são incluídas estruturas auxiliares, tabelas de estágio e resultados previamente agregados. Para a descrição do domínio e para as etapas do trabalho, foram selecionadas 15 tabelas principais, por serem as que representam de forma direta as entidades e os eventos relevantes da Fórmula 1.

Tabela 1 – Tabelas principais da base F1

Tabela	Descrição	Registros	Atributos
circuits	Circuitos das corridas.	77	9
constructor_results	Resultados das equipes em cada corrida.	12.545	5
constructor_standings	Classificação das equipes.	13.311	7
constructors	Cadastro das equipes.	212	5
driver_standings	Classificação dos pilotos.	34.680	7
drivers	Cadastro dos pilotos.	860	9
lap_times	Tempos de volta.	580.619	6
pit_stops	Paradas nos boxes.	11.120	7
position_descriptions	Descrição das posições.	6	2
qualifying	Resultados da classificação.	10.334	9
races	Informações das corridas.	1.125	18
results	Resultado final dos pilotos.	26.599	18
seasons	Temporadas.	75	2
sprint_results	Resultados das corridas sprint.	300	16
status	Situação final dos pilotos.	139	2

Fonte: elaboração própria a partir da base F1.

Os atributos dessas tabelas aparecem nos tipos INTEGER, DOUBLE, VARCHAR e DATE. Os principais vínculos entre as entidades são feitos por constructorId, raceId, circuitId e statusId. A tabela results foi escolhida como ponto de partida da mineração porque cada linha registra o desempenho de um piloto em uma corrida. Ela foi relacionada a constructors e races; já circuits e status foram utilizadas como apoio na exploração e na verificação da qualidade dos dados.

3 Preparação dos dados da base F1

3.1 Seleção e qualidade dos dados

Como cada linha de `results` representa o desempenho de um piloto em uma corrida, essa tabela concentrou a maior parte dos atributos usados no estudo: `grid`, `position`, `points`, `constructorId`, `raceId` e `statusId`. Das tabelas relacionadas foram aproveitados o nome da equipe, o ano, o circuito, o país e a descrição do status.

Na verificação de qualidade, foram encontrados 10.932 valores ausentes em `position`, correspondentes a 41,10% dos 26.599 resultados. Esses casos não foram tratados como simples erros, pois estão ligados, em grande parte, a abandonos, acidentes e falhas mecânicas. Por isso, permaneceram na base e foram representados pela categoria `Abandono`. Não foram encontradas linhas completamente duplicadas. Também foi feita a padronização das formas *USA* e *United States* quando o país foi usado na análise exploratória.

Alguns atributos foram deixados de fora das transações, como identificadores individuais de pilotos, URLs, tempos detalhados, melhor volta e velocidade máxima. Embora sejam informações válidas, elas tenderiam a gerar itens muito específicos e pouco úteis para as regras que se pretendia investigar.

3.2 Discretização e transações

Para a mineração, foram considerados apenas os registros com posição de largada maior que zero, o que resultou em 24.966 transações na série completa. A posição no grid foi agrupada em três faixas: `Grid_Front`, para as posições de 1 a 6; `Grid_Middle`, de 7 a 12; e `Grid_Back`, acima de 12. O desempenho final também foi convertido em uma única categoria: `Venceu`, `Podio` para segundo ou terceiro lugar, `Pontuou`, `Nao_Pontuou` ou `Abandono`.

Para evitar um número muito grande de equipes com poucas ocorrências, as 18 equipes com pelo menos 500 resultados foram mantidas pelo nome. As demais foram reunidas em `Equipe_Outras`. Assim, cada transação usada pelo Apriori passou a ter exatamente três itens: faixa de largada, categoria de resultado e equipe.

```
{Grid_Front, Venceu, Equipe_Ferrari}
```


Essa estrutura também resolve uma divergência presente em uma versão preliminar do texto, na qual temporada, circuito, país e status apareciam como parte das transações. Os códigos finais, entretanto, utilizam apenas `grid`, `resultado` e `equipe`, e o relatório foi ajustado para refletir essa implementação.

4 Caracterização exploratória da base F1

4.1 Evolução histórica

A série histórica cobre 75 temporadas, de 1950 a 2024, com 1.125 corridas registradas. Ao longo desse período, o calendário cresceu de cerca de sete provas nas primeiras temporadas para 24 em 2024. A queda observada em 2020 foge da tendência geral, mas é compatível com as restrições que afetaram o campeonato naquele ano.

Figura 1 – Evolução da Fórmula 1 ao longo das temporadas




Fonte: elaboração própria a partir da base F1.

4.2 Participação e desempenho das equipes


Ferrari, McLaren e Williams são as equipes com maior número de Grandes Prêmios disputados. Como esse total depende diretamente do tempo de permanência na categoria, também foi calculada a taxa de vitórias entre equipes com pelo menos cem corridas. Esse segundo indicador permite comparar desempenho sem depender apenas de valores absolutos.

Figura 2 – Grandes Prêmios disputados por equipe



Fonte: elaboração própria a partir da base F1.

Figura 3 – Taxa de vitória por equipe



Fonte: elaboração própria a partir da base F1. Foram consideradas equipes com pelo menos cem Grandes Prêmios.


Nesse recorte, a Mercedes apresenta a maior taxa de vitória, seguida por Red Bull, Ferrari e McLaren. O resultado mostra por que a taxa relativa é importante: uma equipe pode não liderar

em vitórias absolutas e, ainda assim, ter aproveitamento superior quando se considera o número de participações.

4.3 Nacionalidades e domínio por década


Os pilotos britânicos concentram o maior número de vitórias, seguidos pelos alemães e brasileiros. Quando o desempenho é observado por década, percebe-se uma alternância entre equipes dominantes: Ferrari nos anos 1950, 1970 e 2000; Lotus-Climax nos anos 1960; McLaren nos anos 1980; Williams nos anos 1990; Mercedes nos anos 2010; e Red Bull nos anos 2020.

Figura 4 – Nacionalidade dos pilotos vencedores



Fonte: elaboração própria a partir da base F1.

Figura 5 – Equipe com maior número de vitórias em cada década




Fonte: elaboração própria a partir da base F1.

Essa alternância ajuda a explicar por que foram feitos experimentos separados por período. Uma análise única das 75 temporadas favorece padrões muito gerais e pode esconder relações que só fazem sentido em contextos históricos específicos.

4.4 Distribuição, correlação e valores extremos


A posição de largada tem mediana 12 e intervalo interquartil entre 6 e 17. Pelo critério do IQR, apenas um registro, com grid 34, ultrapassa o limite superior de 33,5. A distribuição dos pontos é bem mais assimétrica: a mediana é zero e 16.889 dos 24.966 resultados com grid válido não registram pontuação. O mesmo critério classifica como extremos os valores acima de cinco pontos, totalizando 3.813 casos. Esses registros foram preservados porque são compatíveis com o domínio, refletindo colocações de alta pontuação e situações particulares do regulamento, como a corrida com pontuação dobrada em 2014.

Figura 6 – Distribuição da pontuação obtida pelos pilotos




Fonte: elaboração própria a partir da base F1.

Figura 7 – Boxplot da posição de largada



Fonte: elaboração própria a partir da base F1.


Figura 8 – Boxplot da pontuação obtida



Fonte: elaboração própria a partir da base F1.

A correlação entre grid e posição final foi de 0,64. Como valores menores indicam melhores colocações, o sinal positivo mostra que largadas em posições numericamente baixas tendem a estar associadas a chegadas também numericamente baixas. Já a posição final apresentou correlação de -0,65 com os pontos, enquanto o grid teve correlação de -0,55 com a pontuação. Esses valores confirmam tendências esperadas do esporte, mas não isolam fatores como desempenho do carro, estratégia ou habilidade do piloto.

Figura 9 – Matriz de correlação das variáveis numéricas da base F1



Fonte: elaboração própria a partir da base F1.

5 Modelagem e extração das regras da base F1

5.1 Estratégia e parâmetros

Cada resultado de piloto em uma corrida foi tratado como uma transação. O Apriori foi executado com suporte mínimo de 0,02 e confiança mínima de 0,60. Os mesmos limites foram usados na série completa, nas temporadas de 1950–1959 e no período de 2014–2024, de modo que as diferenças entre os resultados pudessem ser atribuídas ao recorte histórico, e não à mudança de parâmetros.

Tabela 2 – Resumo dos experimentos de regras na base F1

Período	Transações	Itens	Itemsets	Regras	Ocorrências mínimas
1950–2024	24.966	27	61	9	aproximadamente 500
1950–1959	1.939	13	48	17	aproximadamente 39
2014–2024	4.392	17	73	21	aproximadamente 88

Fonte: elaboração própria. Regras contabilizadas com confiança mínima de 60%.

A confiança, por si só, pode parecer alta quando o consequente já é muito frequente. Por esse motivo, o lift foi recalculado e usado como apoio na seleção final. No recorte de 1950–1959, por exemplo, apenas nove das 17 regras atingiram lift igual ou superior a 1,10.

5.2 Base completa: 1950–2024

Tabela 3 – Regras da base completa da Fórmula 1 (1950–2024)

Regra	Suporte	Confiança	Lift	Interpretação
{Venceu} → {Grid_Front}	4,15%	92,50%	3.43	A vitória aparece fortemente associada às seis primeiras posições de largada. É um padrão esperado, útil principalmente como validação da estratégia transacional.
{Podio} → {Grid_Front}	6,78%	75,13%	2.79	Resultados de segundo ou terceiro lugar concentram-se entre pilotos que largaram na parte dianteira do grid.
{Equipe_Ferrari} → {Grid_Front}	6,16%	64,03%	2.37	A Ferrari aparece historicamente associada às primeiras posições de largada, refletindo sua presença prolongada entre as equipes competitivas.

Tabela 3 – continuação

Regra	Suporte	Confiança	Lift	Interpretação
{Equipe_Minardi} → {Grid_Back}	2,42%	94,23%	2.05	A Minardi apresenta concentração muito elevada no fundo do grid. O suporte é menor, pois a equipe participou de apenas parte da série histórica.
{Nao_Pontuou, Equipe_Outras} → {Grid_Back}	10,60%	74,96%	1.63	Entre equipes agrupadas como outras, a ausência de pontuação ocorre frequentemente após largadas no fundo do grid.
{Nao_Pontuou} → {Grid_Back}	20,90%	69,14%	1.50	A ausência de pontuação está associada ao fundo do grid, mas a relação não deve ser interpretada como causalidade.
{Abandono, Equipe_Outras} → {Grid_Back}	10,46%	64,87%	1.41	Abandonos de equipes menos frequentes aparecem associados às últimas posições de largada; o agrupamento heterogêneo exige cautela.
{Equipe_Tyrrell} → {Grid_Back}	2,11%	62,29%	1.35	A associação resume o desempenho agregado da Tyrrell em toda a série, mas pode ocultar fases historicamente distintas da equipe.
{Equipe_Outras} → {Grid_Back}	22,89%	60,32%	1.31	O agrupamento de equipes de menor frequência concentra largadas no fundo do grid; a regra é abrangente, porém pouco específica.

Fonte: elaboração própria a partir da base F1.

5.3 Era híbrida: 2014–2024

Tabela 4 – Regras representativas da era híbrida (2014–2024)

Regra	Suporte	Confiança	Lift	Interpretação
{Equipe_Mercedes, Venceu} → {Grid_Front}	2,57%	98,26%	3.27	Quase todas as vitórias da Mercedes na era híbrida ocorreram após largadas entre as seis primeiras posições.
{Venceu} → {Grid_Front}	4,80%	95,91%	3.20	Na era híbrida, a relação entre vitória e largada na frente tornou-se ainda mais forte do que na série completa.
{Equipe_Ferrari, Podio} → {Grid_Front}	2,50%	94,02%	3.13	Os pódios da Ferrari no período moderno aparecem quase sempre precedidos por largadas na frente.
{Equipe_Mercedes} → {Grid_Front}	8,33%	83,37%	2.78	A Mercedes esteve fortemente concentrada nas primeiras posições do grid entre 2014 e 2024.
{Equipe_Red Bull} → {Grid_Front}	6,94%	71,10%	2.37	A Red Bull também apresenta associação expressiva com largadas dianteiras no período moderno.
{Equipe_Sauber, Nao_Pontuou} → {Grid_Back}	3,10%	91,28%	2.28	Quando a Sauber não pontuou, em mais de 91% dos casos analisados largou no fundo do grid.
{Equipe_Williams, Grid_Back} → {Nao_Pontuou}	4,42%	72,66%	2.10	Largadas da Williams no fundo do grid estiveram associadas à ausência de pontuação na era híbrida.
{Equipe_Ferrari, Pontuou} → {Grid_Front}	3,01%	62,86%	2.09	Parte relevante das corridas em que a Ferrari pontuou foi iniciada entre as primeiras posições.

Tabela 4 – continuação

Regra	Suporte	Confiança	Lift	Interpretação
{Equipe_Sauber, Grid_Back} → {Nao_Pontuou}	3,10%	70,10%	2.02	A combinação Sauber e fundo do grid aumenta significativamente a ocorrência de resultados sem pontos.
{Equipe_Outras, Grid_Front} → {Pontuou}	2,16%	67,86%	1.95	Mesmo equipes agrupadas como outras pontuaram com frequência quando conseguiram largar na frente.
{Grid_Back, Equipe_Outras} → {Nao_Pontuou}	12,75%	66,59%	1.92	Equipes menos frequentes que largaram no fundo do grid terminaram sem pontos em cerca de dois terços dos registros.
{Grid_Back} → {Nao_Pontuou}	24,89%	62,10%	1.79	No período moderno, largar no fundo do grid esteve positivamente associado a não pontuar.

Fonte: elaboração própria a partir da base F1.

5.4 Primeiras temporadas: 1950–1959

Tabela 5 – Regras positivas das primeiras temporadas (1950–1959)

Regra	Suporte	Confiança	Lift	Interpretação
{Venceu} → {Grid_Front}	3,92%	87,36%	3.17	A associação entre vitória e largada dianteira já era forte nas primeiras temporadas.
{Equipe_Ferrari, Podio} → {Grid_Front}	3,40%	75,86%	2.75	Os pódios da Ferrari nos anos 1950 estiveram concentrados nas primeiras posições do grid.
{Podio} → {Grid_Front}	6,29%	65,59%	2.38	Mesmo no início da categoria, segundo e terceiro lugares apresentavam associação positiva com largadas na frente.
{Nao_Pontuou, Equipe_Outras} → {Grid_Back}	15,21%	65,41%	1.47	Entre equipes agrupadas como outras, resultados sem pontos apareceram associados ao fundo do grid.
{Nao_Pontuou} → {Grid_Back}	16,97%	60,70%	1.37	A ausência de pontuação já se concentrava nas últimas posições de largada, embora com força menor que na era moderna.
{Nao_Pontuou, Grid_Back} → {Equipe_Outras}	15,21%	89,67%	1.20	A confiança é alta, mas o lift é moderado porque o item Equipe_Outras é muito frequente nos anos 1950.
{Grid_Back} → {Equipe_Outras}	39,35%	88,72%	1.18	A maioria das largadas no fundo pertencia ao agrupamento de equipes menos frequentes; o resultado é influenciado pelo tamanho desse grupo.
{Abandono, Grid_Back} → {Equipe_Outras}	21,66%	88,24%	1.18	Abandonos no fundo do grid concentraram-se em equipes agrupadas como outras, possivelmente refletindo menor competitividade e confiabilidade.
{Nao_Pontuou} → {Equipe_Outras}	23,26%	83,21%	1.11	A associação é positiva, porém próxima do limite adotado e fortemente condicionada pela frequência elevada do agrupamento.

Fonte: elaboração própria a partir da base F1.

6 Análise crítica e perguntas da base F1

6.1 Auditoria das regras

Tabela 6 – Auditoria crítica das regras da base F1

Regra ou grupo	Classificação	Discussão
{Venceu} → {Grid_Front}	Esperada, mas válida	A regra possui lift superior a 3 nos três experimentos. Embora pouco surpreendente, confirma que a transformação dos dados preservou uma relação esportiva central.
{Podio} → {Grid_Front}	Esperada	Também funciona como regra de validação. Sua força aumenta na era híbrida, indicando maior concentração do desempenho entre equipes de ponta.
Regras envolvendo Mercedes, Red Bull, Sauber e Williams	Específicas do período	São mais informativas do que as regras gerais porque descrevem padrões característicos de 2014–2024. Não devem ser extrapoladas para toda a história.
Regras com Equipe_Outras	Sensíveis ao agrupamento	O item reúne equipes heterogêneas. Nos anos 1950, ele aparece em grande parte das transações, elevando a confiança de regras cujo lift é apenas moderado.
Regras de 1950–1959 com lift inferior a 1,10	Descartadas	Das 17 regras geradas por suporte e confiança, oito não atingiram lift 1,10; seis possuíam lift inferior a 1, indicando ausência de associação positiva. Elas não foram usadas nas perguntas finais.
{Pontuou} → {Equipe_Outras} nos anos 1950	Não relevante	Apesar da confiança de 65,41%, o lift foi 0,87. O consequente era tão frequente que a regra ocorria menos do que o esperado sob independência.
Relações entre grid e resultado	Coocorrência, não causa	Largar na frente está associado a melhores resultados, mas as regras não isolam fatores como desempenho do carro, habilidade do piloto, estratégia ou confiabilidade.
Mudanças no sistema de pontuação	Limitação histórica	A categoria Pontuou reduz diferenças entre regulamentos, porém não elimina completamente o efeito das mudanças ocorridas ao longo de 75 temporadas.

Fonte: elaboração própria.

A comparação dos três experimentos mostra que as relações entre vitória, pódio e boas posições de largada se repetem em todos os períodos. Já as regras ligadas a equipes específicas são mais interessantes para caracterizar uma época, embora não possam ser estendidas automaticamente a toda a história. Nos anos 1950, a interpretação exige atenção adicional porque o grupo Equipe_Outras aparece em grande parte das transações e reúne equipes bastante diferentes entre si.

6.2 Perguntas e respostas

Foram escolhidas 15 perguntas para a base F1, distribuídas entre a série completa, a era híbrida e as primeiras temporadas. A quantidade foi definida após a retirada de regras repetitivas,

excessivamente óbvias ou com lift insuficiente. Somadas às 30 perguntas da base *movie_recomm*, elas formam as 45 perguntas e respostas apresentadas no trabalho.

Tabela 7 – Perguntas e respostas derivadas das regras da base F1

Nº	Regra	Pergunta	Resposta
1	{Venceu} → {Grid_Front}	Por que as vitórias aparecem associadas às primeiras posições do grid?	Na série completa, 1.036 das 1.120 vitórias analisadas ocorreram após largadas entre as seis primeiras posições, resultando em confiança de 92,50% e lift 3,43. A regra indica coocorrência forte, mas não prova causalidade.
2	{Podio} → {Grid_Front}	Por que os pódios aparecem frequentemente ligados à parte dianteira do grid?	Dos 2.252 resultados classificados como segundo ou terceiro lugar, 1.692 partiram da frente do grid. A confiança de 75,13% e o lift 2,79 mostram associação consistente ao longo da história.
3	{Equipe_Ferrari} → {Grid_Front}	O que a regra revela sobre a Ferrari na série histórica?	Entre 2.402 resultados da Ferrari com posição de largada válida, 1.538 ocorreram nas seis primeiras posições. O padrão possui confiança de 64,03% e lift 2,37.
4	{Equipe_Minardi} → {Grid_Back}	Por que a Minardi aparece fortemente associada ao fundo do grid?	Dos 641 resultados da Minardi, 604 partiram após a 12ª posição. A confiança de 94,23% e o lift 2,05 evidenciam concentração histórica nas últimas posições.
5	{Nao_Pontuou} → {Grid_Back}	Existe associação entre não pontuar e largar no fundo do grid?	Sim. Na base completa, 5.218 dos 7.547 resultados sem pontuação partiram do fundo do grid. A confiança foi 69,14% e o lift 1,50.
6	{Equipe_Mercedes, Venceu} → {Grid_Front}	Como ocorreram as vitórias da Mercedes entre 2014 e 2024?	No período, 113 das 115 vitórias da Mercedes partiram das seis primeiras posições. A confiança de 98,26% e o lift 3,27 indicam associação muito forte.
7	{Equipe_Mercedes} → {Grid_Front}	A Mercedes largou frequentemente na frente durante a era híbrida?	Sim. Dos 439 resultados da equipe no recorte, 366 partiram da frente do grid, com confiança de 83,37% e lift 2,78.
8	{Equipe_Red Bull} → {Grid_Front}	Qual padrão foi encontrado para a Red Bull no período moderno?	Entre 429 resultados da Red Bull, 305 ocorreram nas seis primeiras posições de largada. A confiança foi 71,10% e o lift 2,37.
9	{Equipe_Sauber, Nao_Pontuou} → {Grid_Back}	Quando a Sauber não pontuou, de onde normalmente largou?	Em 136 dos 149 casos sem pontuação, a Sauber largou no fundo do grid. A confiança alcançou 91,28% e o lift 2,28.
10	{Equipe_Williams, Grid_Back} → {Nao_Pontuou}	O que ocorreu quando a Williams largou no fundo do grid entre 2014 e 2024?	Das 267 ocorrências, 194 terminaram sem pontuação. A confiança de 72,66% e o lift 2,10 mostram associação relevante no período.
11	{Equipe_Outras, Grid_Front} → {Pontuou}	Equipes menos frequentes conseguiram pontuar quando largaram na frente?	Sim. Entre 140 registros do agrupamento Equipe_Outras na frente do grid, 95 terminaram com pontos. A confiança foi 67,86% e o lift 1,95.
12	{Grid_Back} → {Nao_Pontuou}	Na era híbrida, largar no fundo esteve associado a não pontuar?	Dos 1.760 resultados iniciados após a 12ª posição, 1.093 terminaram sem pontos. A confiança foi 62,10% e o lift 1,79.

Continua na próxima página

Tabela 7 – continuação

Nº	Regra	Pergunta	Resposta
13	{Equipe_Ferrari, Podio} → {Grid_Front}	Como foram os pódios da Ferrari nas primeiras temporadas?	Entre 87 pódios da Ferrari nos anos 1950, 66 partiram da frente do grid. A confiança foi 75,86% e o lift 2,75.
14	{Nao_Pontuou, Grid_Back} → {Equipe_Outras}	Por que resultados sem pontos no fundo do grid aparecem ligados a Equipe_Outras nos anos 1950?	Dos 329 registros com essa combinação, 295 pertenciam ao agrupamento. A confiança foi 89,67%, mas o lift de 1,20 exige cautela porque Equipe_Outras era muito frequente.
15	{Abandono, Grid_Back} → {Equipe_Outras}	O que a associação entre abandono, fundo do grid e equipes agrupadas indica?	Nos anos 1950, 420 dos 476 abandonos ocorridos no fundo do grid pertenciam a Equipe_Outras. O lift 1,18 indica associação positiva moderada, influenciada pelo agrupamento.

Fonte: elaboração própria a partir da base F1.

Parte II

Base Movie Recommendation Database

7 Compreensão da base escolhida

7.1 Nome e domínio da base

A segunda base analisada é a *Movie Recommendation Database* (*movie_recomm*). Ela reúne informações de cinema e de sistemas de recomendação, incluindo filmes, pessoas envolvidas nas produções, personagens, categorias, palavras-chave e avaliações feitas por usuários.

Embora o banco represente várias entidades, a estratégia deste trabalho se concentrou em filmes, usuários e avaliações. Essa escolha permitiu estudar padrões envolvendo características das produções e a forma como elas foram avaliadas.

7.2 Tabelas analisadas

Tabela 8 – Tabelas principais da base *movie_recomm*

Tabela	Descrição	Registros	Atributos
all_casts	Relação entre filmes, pessoas e funções desempenhadas na produção.	1.242.442	5
all_categories	Cadastro das categorias existentes na base.	15.218	3
all_characters	Cadastro dos personagens presentes nos filmes.	1.524	2
all_movie_aliases_iso	Títulos alternativos dos filmes em diferentes idiomas.	297.374	4
all_people	Cadastro das pessoas envolvidas nas produções cinematográficas.	287.868	5
category_names	Nomes das categorias em diferentes idiomas.	56.201	3
job_names	Nomes das funções exercidas na produção.	2.145	3
movie_categories	Associação entre filmes e suas categorias.	224.751	2
movie_keywords	Associação entre filmes e palavras-chave.	413.255	2
movielens_movies	Cadastro dos filmes utilizados pelo conjunto MovieLens.	9.742	3
movielens_ratings	Avaliações realizadas pelos usuários sobre os filmes.	100.836	4

Fonte: elaboração própria a partir da base *movie_recomm*.

A base possui 11 tabelas principais, distribuídas entre o cadastro de filmes, pessoas, funções, categorias, palavras-chave e avaliações.

7.3 Tipos de atributos

Os atributos presentes na base estão distribuídos entre os seguintes tipos:

- INTEGER: identificadores e valores inteiros;
- DOUBLE: avaliações numéricas com casas decimais;
- VARCHAR: informações textuais, como nomes, títulos e gêneros.

7.4 Relacionamentos relevantes

Tabela 9 – Relacionamentos relevantes entre as tabelas

Tabela principal	Chave de ligação	Tabelas relacionadas
all_people	person_id	all_casts
job_names	job_id	all_casts
category_names	category_id	movie_categories e movie_keywords
all_movie_aliases_iso	movie_id	all_casts, movie_categories e movie_keywords
movielens_movies	movieId	movielens_ratings

Fonte: elaboração própria.

Nem todos os vínculos aparecem declarados como chaves estrangeiras, mas eles podem ser reconhecidos pelas colunas em comum. Para a mineração, foi usado o relacionamento direto entre `movielens_movies` e `movielens_ratings`, estabelecido pelo campo `movieId`.

7.5 Justificativa da seleção

A compreensão inicial contemplou as 11 tabelas principais. Nas etapas seguintes, porém, foram utilizadas apenas `movielens_movies` e `movielens_ratings`. Além de possuírem ligação direta, elas oferecem quantidade suficiente de registros e os atributos necessários para investigar associações entre gêneros, período de lançamento, avaliação média e popularidade.

8 Preparação dos dados

8.1 Seleção das tabelas e dos atributos

As etapas de preparação, análise exploratória e mineração utilizaram as tabelas `movielens_movies` e `movielens_ratings`. A primeira reúne o identificador, o título e os gêneros de 9.742 filmes. A segunda registra 100.836 avaliações feitas por 610 usuários, com o filme avaliado, a nota e o momento em que a avaliação foi realizada.

Tabela 10 – Atributos selecionados e suas finalidades

Tabela	Atributo	Finalidade
<code>movielens_movies</code>	<code>movieId</code>	Identificação e relacionamento do filme.
<code>movielens_movies</code>	<code>title</code>	Título e extração do ano de lançamento.
<code>movielens_movies</code>	<code>genres</code>	Construção dos itens de gênero.
<code>movielens_ratings</code>	<code>userId</code>	Identificação do usuário e auditoria de duplicatas.
<code>movielens_ratings</code>	<code>movieId</code>	Relacionamento com o cadastro de filmes.
<code>movielens_ratings</code>	<code>rating</code>	Cálculo das estatísticas de avaliação.
<code>movielens_ratings</code>	<code>timestamp</code>	Conversão para data e identificação do intervalo temporal das avaliações.

Fonte: elaboração própria.

As demais tabelas descrevem outro conjunto cinematográfico, com elenco, pessoas, categorias e palavras-chave. Como não há uma ligação direta documentada entre esses identificadores e os códigos do MovieLens, elas não foram combinadas com as avaliações nesta estratégia.

8.2 Qualidade e integridade dos dados

Os atributos essenciais não apresentaram valores nulos. Todas as avaliações possuem um filme correspondente e não foram encontradas duplicatas da combinação `userId` e `movieId`. A auditoria identificou 18 filmes sem avaliação, 34 filmes marcados como “(no genres listed)”, 13 títulos sem ano no padrão esperado e cinco pares de títulos iguais associados a identificadores diferentes.

Os títulos repetidos foram preservados porque os registros possuem identificadores próprios e, em alguns casos, gêneros distintos. Filmes sem avaliação ou sem gênero conhecido continuaram registrados no relatório de qualidade, mas ficaram fora da mineração. Os textos foram padronizados, os campos numéricos foram convertidos para os tipos adequados e o `timestamp` foi transformado em data e hora.

Os gêneros foram separados pelo delimitador original e normalizados para minúsculas, sem acentos e com sublinhados, originando itens como `genero_acao` e `genero_ficcao_cientifica`.

O campo `movieId` permaneceu apenas como identificador; `title` foi usado para extrair o ano; `userId` serviu à auditoria e à agregação; e `timestamp` foi útil para a verificação temporal, mas não entrou nas transações. A mediana também não foi discretizada porque apresentou correlação muito alta com a média e acrescentaria uma informação praticamente repetida.

Tabela 11 – Resumo da qualidade dos dados

Indicador	Resultado	Observação
Filmes sem avaliação	18	Mantidos somente na auditoria.
Avaliações órfãs	0	Todas possuem filme correspondente.
Duplicatas usuário-filme	0	Nenhuma duplicata encontrada.
Filmes sem gênero informado	34	Excluídos das transações.
Filmes usados nas transações	3.649	Mínimo de cinco avaliações.

Fonte: elaboração própria.

8.3 Agregação e criação de variáveis

As avaliações foram reunidas por filme. Para cada produção, foram calculadas a quantidade de avaliações, a média, a mediana, o desvio-padrão, além das datas da primeira e da última avaliação. Para evitar que poucas notas produzissem médias pouco estáveis, foram mantidos apenas filmes com pelo menos cinco avaliações e gênero conhecido. Com esse critério, o conjunto final ficou com 3.649 filmes.

Tabela 12 – Variáveis derivadas e critérios de discretização

Nova variável	Definição
<code>ano_lancamento</code>	Ano extraído do final do título.
<code>periodo_lancamento</code>	Antes de 1950; 1950–1969; 1970–1989; 1990–1999; 2000–2009; 2010–2018.
<code>faixa_avaliacao</code>	Baixa: média menor que 3,0; intermediária: 3,0 a menor que 4,0; alta: média igual ou superior a 4,0.
<code>faixa_popularidade</code>	Baixa: 5–9 avaliações; intermediária: 10–49; alta: 50 ou mais.
<code>quantidade_generos</code>	Quantidade de gêneros associados ao filme.

Fonte: elaboração própria.

9 Caracterização exploratória dos dados

9.1 Distribuição das avaliações


As notas dadas pelos usuários variam de 0,5 a 5,0. Nas 100.836 avaliações, a média geral foi de aproximadamente 3,50, a mediana de 3,5 e o desvio-padrão de 1,04. A nota 4,0 foi a mais frequente, seguida pela nota 3,0. A Figura 10 mostra a distribuição das avaliações individuais, enquanto a Figura 11 apresenta as médias por filme depois do filtro mínimo de cinco avaliações e da exclusão de produções sem gênero conhecido.

Tabela 13 – Estatísticas descritivas das variáveis principais

Variável	N	Média	Mediana	Desvio-padrão	Mínimo	Máximo
Avaliações individuais	100.836	3,50	3,50	1,04	0,50	5,00
Média por filme	3.649	3,35	3,43	0,59	1,06	4,90
Quantidade de avaliações por filme	3.649	24,74	14,00	30,29	5	329
Ano de lançamento	3.649	1994,85	1997	18,07	1902	2018
Quantidade de gêneros por filme	3.649	2,55	2	1,12	1	7


Fonte: elaboração própria.

Figura 10 – Distribuição das notas atribuídas pelos usuários



Fonte: elaboração própria a partir da base *movie_recomm*.

Figura 11 – Distribuição das médias de avaliação dos filmes



Fonte: elaboração própria a partir da base *movie_recomm*.

9.2 Popularidade e valores extremos

A popularidade, medida pela quantidade de avaliações, é bastante desigual. Na base completa, a mediana é de três avaliações por filme e o máximo chega a 329. Os gráficos desta seção consideram os 3.649 filmes preparados, todos com pelo menos cinco avaliações.

Nesse grupo, 1.380 filmes foram classificados com baixa popularidade, 1.819 com popularidade intermediária e 450 com alta popularidade. Na Figura 12, foi usada escala logarítmica no eixo vertical para que as faixas mais comuns e a cauda da distribuição pudessem ser vistas no mesmo gráfico.


Pelo método do intervalo interquartil, apareceram 335 valores extremos na quantidade de avaliações, 32 na média e 85 no desvio-padrão. Esses casos foram mantidos, pois não indicavam erros: em geral, representavam filmes muito populares ou avaliações com comportamento realmente diferente da maioria.

Tabela 14 – Possíveis valores extremos segundo o intervalo interquartil

Variável	Possíveis outliers
Quantidade de avaliações	335
Média das avaliações	32
Desvio-padrão das avaliações	85

Fonte: elaboração própria.

Figura 12 – Distribuição da quantidade de avaliações entre os filmes preparados



Fonte: elaboração própria. O eixo vertical utiliza escala logarítmica.

superior correspondem a produções que receberam muito mais avaliações do que a maioria. Como não foram encontrados indícios de erro nesses registros, eles permaneceram na análise.

9.3 Frequência dos gêneros e dos períodos


Drama e comédia são os gêneros mais comuns, presentes, respectivamente, em 1.597 filmes (43,77%) e 1.479 filmes (40,53%). Em seguida aparecem ação, com 928 registros (25,43%), e suspense, com 890 (24,39%). Como uma mesma produção pode receber mais de um gênero, os percentuais não somam 100%.

Tabela 15 – Gêneros mais frequentes entre os filmes preparados

Gênero	Filmes	Percentual
Drama	1.597	43,77%
Comédia	1.479	40,53%
Ação	928	25,43%
Suspense	890	24,39%
Aventura	676	18,53%

Fonte: elaboração própria.


Figura 15 – Gêneros mais frequentes entre os filmes preparados



Fonte: elaboração própria a partir da base *movie_recomm*.

A maior concentração de filmes está nos períodos de 2000–2009, com 1.145 registros, e de 1990–1999, com 1.111. Depois aparecem 1970–1989, com 651 filmes, e 2010–2018, com 463. Esse desequilíbrio temporal precisa ser levado em conta, principalmente nas regras que envolvem período de lançamento.

Figura 16 – Quantidade de filmes por período de lançamento



Fonte: elaboração própria a partir da base *movie_recomm*.

As faixas de avaliação e popularidade são importantes na construção das transações. No entanto, os gráficos específicos dessas categorias repetiam informações já visíveis nos histogramas e nas tabelas. Para manter o relatório mais direto, os totais foram apresentados apenas na Tabela 16.

Tabela 16 – Distribuição das faixas discretizadas

Faixa	Definição	Filmes	Percentual
Avaliação baixa	Média menor que 3,0	873	23,92%
Avaliação intermediária	3,0 a menor que 4,0	2.336	64,02%
Avaliação alta	Média igual ou superior a 4,0	440	12,06%
Popularidade baixa	5 a 9 avaliações	1.380	37,82%
Popularidade intermediária	10 a 49 avaliações	1.819	49,85%
Popularidade alta	50 ou mais avaliações	450	12,33%


Fonte: elaboração própria.

9.4 Correlações

A matriz de correlação foi calculada com os 3.649 filmes preparados. A média e a mediana das avaliações apresentaram correlação muito alta, de aproximadamente 0,93, o que é esperado porque ambas resumem o mesmo conjunto de notas. A quantidade de avaliações teve

correlação positiva fraca com a média, em torno de 0,26, enquanto o ano de lançamento mostrou correlação negativa fraca, próxima de -0,19. Esses valores indicam associação linear, mas não permitem afirmar causalidade. Para evitar duplicação de informação nas transações, foi utilizada apenas a faixa baseada na média.

Figura 17 – Matriz de correlação das variáveis numéricas entre os filmes preparados



Fonte: elaboração própria a partir da base *movie_recomm*.

10 Modelagem da estratégia para extração de regras

Na base de filmes, cada produção foi tratada como uma transação. Nela foram reunidos todos os gêneros do filme, o período de lançamento, a faixa da avaliação média e a faixa de popularidade.

```
{genero_animacao, genero_aventura, genero_infantil, periodo_1990_1999,  
avaliacao_media, popularidade_alta}
```

Essa escolha combina três abordagens previstas no enunciado: agregação por entidade, discretização de variáveis numéricas e relacionamento entre tabelas. Também foi considerada a possibilidade de criar transações por usuário, mas essa alternativa produziria apenas 610 transações e provavelmente resultaria em padrões muito gerais de consumo. A modelagem por filme gerou 3.649 transações e tornou mais direta a interpretação das características que aparecem juntas em uma produção.

Em média, cada transação contém 5,545 itens entre gêneros, período, avaliação e popularidade.

11 Extração das regras de associação

As regras foram extraídas com o FP-Growth, disponível na biblioteca *mlxtend*. O algoritmo foi escolhido porque encontra conjuntos frequentes sem precisar gerar explicitamente todos os candidatos do Apriori, o que é adequado para o número de combinações existente nas transações de filmes.

Tabela 17 – Parâmetros utilizados na extração das regras

Parâmetro	Valor
Algoritmo	FP-Growth
Suporte mínimo	0,02 (2%)
Confiança mínima	0,55 (55%)
Lift mínimo da extração inicial	1,10
Lift mínimo para as regras finais	1,30
Tamanho máximo do itemset	4 itens
Máximo de itens no antecedente	2 itens
Consequente	Exatamente 1 item

Fonte: elaboração própria.

Com 3.649 transações, o suporte de 2% corresponde a cerca de 73 filmes. A confiança mínima de 55% mantém regras em que o consequente aparece na maioria das ocorrências do antecedente. Na primeira etapa, foi usado lift mínimo de 1,10 para permitir a auditoria de associações ainda relativamente fracas. Para a seleção final, o limite subiu para 1,30, de modo que o consequente precisasse ocorrer pelo menos 30% acima de sua frequência geral.

Tabela 18 – Resultados do processo de extração e filtragem

Resultado	Quantidade
Transações	3.649
Itens distintos	31
Itemsets frequentes	501
Regras após os filtros iniciais	121
Regras após remoção de extensões redundantes	85
Regras com lift igual ou superior a 1,30	38
Regras após exclusão das associações óbvias	33
Regras após controle de direções equivalentes	31
Regras selecionadas para perguntas e respostas	30

Fonte: elaboração própria.

A filtragem foi feita em quatro etapas. Primeiro, foram retiradas extensões de antecedente que aumentavam a confiança em menos de cinco pontos percentuais. Depois, ficaram de fora as regras com lift inferior a 1,30. Em seguida, foram removidas associações muito óbvias

entre rótulos próximos. Por último, quando duas direções representavam praticamente a mesma combinação de itens, foi mantida apenas a mais informativa. Esse processo reduziu repetições e evitou que o resultado final fosse dominado por relações triviais de classificação.

12 Análise crítica das regras relevantes

A seleção das regras considerou suporte, confiança e lift em conjunto. A confiança sozinha pode parecer elevada quando o consequente já ocorre com muita frequência. Por isso, o lift foi importante para separar associações realmente acima do esperado de resultados explicados apenas pela concentração das faixas intermediárias de avaliação e popularidade.

12.1 Regras óbvias, redundantes ou pouco úteis

Tabela 19 – Exemplos de regras auditadas e decisões de filtragem

Regra ou grupo	Indicador	Decisão
{animação} → {infantil}	Lift 7,53	Excluída da tabela final por ser uma associação direta entre rótulos editoriais fortemente sobrepostos.
{mistério} → {suspense}	Lift 2,75	Correta, porém com baixa novidade devido à proximidade temática amplamente conhecida.
{drama, popularidade média} → {avaliação média}	Lift 1,14	Confiança alta, mas associação apenas 14% acima da frequência-base da avaliação intermediária.
Direções alternativas de {animação, aventura, infantil}	Mesmo suporte conjunto	Foi mantida somente a direção com melhor equilíbrio de lift e confiança, evitando perguntas quase repetidas.

Fonte: elaboração própria.

As regras retiradas da seleção final não são necessariamente erradas. Elas foram mantidas no arquivo de auditoria porque ajudam a mostrar que o algoritmo reconheceu relações conhecidas. Ainda assim, não foram usadas nas 30 perguntas, já que o enunciado pede atenção especial a padrões óbvios, redundantes ou pouco úteis.

12.2 Discussão de regras representativas

Tabela 20 – Discussão crítica de regras representativas

Regra	Suporte	Confiança	Lift	Discussão
{genero_imax} → {periodo_2010_2018}	2.19%	66.12%	5.21	A concentração de títulos IMAX no período mais recente é coerente com a expansão comercial do formato. O padrão pode ser influenciado pelo recorte temporal e por relançamentos catalogados.
{genero_acao, genero_fantasia} → {genero_aventura}	2.27%	74.11%	4.00	A combinação ação-fantasia associa-se a aventura muito acima do esperado. Isso caracteriza filmes de espetáculo, mas os rótulos podem ter sido atribuídos em conjunto.

Tabela 20 – continuação

Regra	Suporte	Confiança	Lift	Discussão
{genero_aventura, genero_suspense} → {genero_acao}	3.15%	85.19%	3.35	A confiança acima de 85% torna o antecedente muito informativo para ação. O suporte é baixo, porém ainda representa mais de cem filmes, sendo útil para descrever híbridos de gênero.
{avaliacao_media, genero_infantil} → {genero_aventura}	3.12%	56.72%	3.06	Entre filmes infantis com avaliação intermediária, aventura aparece mais de três vezes acima de sua frequência geral. A avaliação apenas delimita o subconjunto e não deve ser tratada como causa.
{genero_ficcao_cientifica, periodo_2010_2018} → {genero_acao}	2.25%	74.55%	2.93	Filmes recentes de ficção científica estão fortemente associados à ação, compatível com grandes produções e franquias do período. O recorte até 2018 e o perfil dos usuários podem amplificar o padrão.
{genero_aventura, genero_ficcao_cientifica} → {genero_acao}	3.67%	72.04%	2.83	A combinação aventura-ficção científica costuma assumir estrutura de ação. O lift confirma concentração acima da frequência-base, embora a proximidade temática reduza a novidade.
{genero_acao, genero_crime} → {genero_suspense}	3.59%	63.29%	2.59	A presença conjunta de ação e crime aumenta substancialmente suspense. O padrão faz sentido em narrativas criminais tensas, mas não implica que um gênero produza o outro.
{genero_aventura, periodo_2010_2018} → {genero_acao}	2.36%	64.66%	2.54	Aventura no período recente aparece ligada à ação, possivelmente pelo predomínio de blockbusters. A interpretação deve considerar o tamanho menor do período 2010–2018.
{avaliacao_baixa, genero_romance} → {genero_comedia}	2.47%	67.67%	1.67	Romances de avaliação baixa aparecem frequentemente como comédias, sugerindo concentração de comédias românticas nesse subconjunto. Pode refletir preferências dos usuários.
{genero_ficcao_cientifica, periodo_2010_2018} → {popularidade_media}	2.00%	66.36%	1.33	Ficção científica recente concentra-se na popularidade intermediária. Isso mostra que nem todo título recente alcança alta exposição e pode refletir a janela de coleta.

Fonte: elaboração própria a partir das regras filtradas.

O suporte mostra o quanto uma regra aparece na base. A confiança indica em que proporção o consequente ocorre entre as transações que contêm o antecedente. O lift compara essa proporção com a frequência geral do consequente. Mesmo quando as três métricas são altas, a regra continua representando coocorrência, e não causalidade. A composição do catálogo, o desbalanceamento entre períodos, a atribuição de vários gêneros ao mesmo filme e o filtro mínimo de avaliações também influenciam os resultados.

13 Perguntas e respostas derivadas das regras

As 30 perguntas da base de filmes foram elaboradas a partir das regras que permaneceram após a filtragem. O formato em tabela permite verificar, em cada caso, qual regra deu origem à pergunta e como ela foi interpretada no contexto cinematográfico.

Tabela 21 – Perguntas e respostas derivadas das regras de associação

Nº	Regra	Pergunta	Resposta
1	{avaliacao_media, genero_infantil} → {genero_animacao}	Que padrão foi encontrado entre avaliação média intermediária (de 3,0 a menos de 4,0) e gênero infantil e gênero animação?	Entre os 201 filmes com avaliação média intermediária (de 3,0 a menos de 4,0) e gênero infantil, 117 também apresentam gênero animação (58.21%). A combinação representa 3.21% da amostra e possui lift 9.36, logo ocorre acima do que seria esperado pela frequência geral do consequente.
2	{genero_aventura, genero_infantil} → {genero_animacao}	Que padrão foi encontrado entre gênero aventura e gênero infantil e gênero animação?	Entre os 163 filmes com gênero aventura e gênero infantil, 92 também apresentam gênero animação (56.44%). A combinação representa 2.52% da amostra e possui lift 9.07, logo ocorre acima do que seria esperado pela frequência geral do consequente.
3	{genero_imax} → {periodo_2010_2018}	Que padrão foi encontrado entre formato IMAX e lançamento entre 2010 e 2018?	Entre os 121 filmes com formato IMAX, 80 também apresentam lançamento entre 2010 e 2018 (66.12%). A combinação representa 2.19% da amostra e possui lift 5.21, logo ocorre acima do que seria esperado pela frequência geral do consequente.
4	{genero_acao, genero_fantasia} → {genero_aventura}	Que padrão foi encontrado entre gênero ação e gênero fantasia e gênero aventura?	Entre os 112 filmes com gênero ação e gênero fantasia, 83 também apresentam gênero aventura (74.11%). A combinação representa 2.27% da amostra e possui lift 4.00, logo ocorre acima do que seria esperado pela frequência geral do consequente.
5	{genero_aventura, genero_suspense} → {genero_acao}	Que padrão foi encontrado entre gênero aventura e gênero suspense e gênero ação?	Entre os 135 filmes com gênero aventura e gênero suspense, 115 também apresentam gênero ação (85.19%). A combinação representa 3.15% da amostra e possui lift 3.35, logo ocorre acima do que seria esperado pela frequência geral do consequente.
6	{avaliacao_media, genero_infantil} → {genero_aventura}	Que padrão foi encontrado entre avaliação média intermediária (de 3,0 a menos de 4,0) e gênero infantil e gênero aventura?	Entre os 201 filmes com avaliação média intermediária (de 3,0 a menos de 4,0) e gênero infantil, 114 também apresentam gênero aventura (56.72%). A combinação representa 3.12% da amostra e possui lift 3.06, logo ocorre acima do que seria esperado pela frequência geral do consequente.

Continua na próxima página

Tabela 21 – continuação

Nº	Regra	Pergunta	Resposta
7	{genero_ficcao_cientifica, periodo_2010_2018} → {genero_acao}	Que padrão foi encontrado entre gênero ficção científica e lançamento entre 2010 e 2018 e gênero ação?	Entre os 110 filmes com gênero ficção científica e lançamento entre 2010 e 2018, 82 também apresentam gênero ação (74.55%). A combinação representa 2.25% da amostra e possui lift 2.93, logo ocorre acima do que seria esperado pela frequência geral do consequente.
8	{genero_aventura, genero_ficcao_cientifica} → {genero_acao}	Que padrão foi encontrado entre gênero aventura e gênero ficção científica e gênero ação?	Entre os 186 filmes com gênero aventura e gênero ficção científica, 134 também apresentam gênero ação (72.04%). A combinação representa 3.67% da amostra e possui lift 2.83, logo ocorre acima do que seria esperado pela frequência geral do consequente.
9	{genero_acao, genero_crime} → {genero_suspense}	Que padrão foi encontrado entre gênero ação e gênero crime e gênero suspense?	Entre os 207 filmes com gênero ação e gênero crime, 131 também apresentam gênero suspense (63.29%). A combinação representa 3.59% da amostra e possui lift 2.59, logo ocorre acima do que seria esperado pela frequência geral do consequente.
10	{genero_aventura, periodo_2010_2018} → {genero_acao}	Que padrão foi encontrado entre gênero aventura e lançamento entre 2010 e 2018 e gênero ação?	Entre os 133 filmes com gênero aventura e lançamento entre 2010 e 2018, 86 também apresentam gênero ação (64.66%). A combinação representa 2.36% da amostra e possui lift 2.54, logo ocorre acima do que seria esperado pela frequência geral do consequente.
11	{genero_ficcao_cientifica, genero_suspense} → {genero_acao}	Que padrão foi encontrado entre gênero ficção científica e gênero suspense e gênero ação?	Entre os 173 filmes com gênero ficção científica e gênero suspense, 111 também apresentam gênero ação (64.16%). A combinação representa 3.04% da amostra e possui lift 2.52, logo ocorre acima do que seria esperado pela frequência geral do consequente.
12	{avaliacao_baixa, genero_aventura} → {genero_acao}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e gênero aventura e gênero ação?	Entre os 164 filmes com avaliação média baixa (menor que 3,0) e gênero aventura, 105 também apresentam gênero ação (64.02%). A combinação representa 2.88% da amostra e possui lift 2.52, logo ocorre acima do que seria esperado pela frequência geral do consequente.
13	{genero_terror, popularidade_media} → {genero_suspense}	Que padrão foi encontrado entre gênero terror e popularidade intermediária (10 a 49 avaliações) e gênero suspense?	Entre os 144 filmes com gênero terror e popularidade intermediária (10 a 49 avaliações), 88 também apresentam gênero suspense (61.11%). A combinação representa 2.41% da amostra e possui lift 2.51, logo ocorre acima do que seria esperado pela frequência geral do consequente.
14	{genero_imax} → {genero_acao}	Que padrão foi encontrado entre formato IMAX e gênero ação?	Entre os 121 filmes com formato IMAX, 76 também apresentam gênero ação (62.81%). A combinação representa 2.08% da amostra e possui lift 2.47, logo ocorre acima do que seria esperado pela frequência geral do consequente.

Continua na próxima página

Tabela 21 – continuação

Nº	Regra	Pergunta	Resposta
15	{avaliacao_baixa, genero_ficcao_cientifica} → {genero_acao}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e gênero ficção científica e gênero ação?	Entre os 146 filmes com avaliação média baixa (menor que 3,0) e gênero ficção científica, 91 também apresentam gênero ação (62.33%). A combinação representa 2.49% da amostra e possui lift 2.45, logo ocorre acima do que seria esperado pela frequência geral do consequente.
16	{genero_aventura, popularidade_alta} → {genero_acao}	Que padrão foi encontrado entre gênero aventura e popularidade alta (50 ou mais avaliações) e gênero ação?	Entre os 132 filmes com gênero aventura e popularidade alta (50 ou mais avaliações), 81 também apresentam gênero ação (61.36%). A combinação representa 2.22% da amostra e possui lift 2.41, logo ocorre acima do que seria esperado pela frequência geral do consequente.
17	{genero_suspense, popularidade_alta} → {genero_acao}	Que padrão foi encontrado entre gênero suspense e popularidade alta (50 ou mais avaliações) e gênero ação?	Entre os 121 filmes com gênero suspense e popularidade alta (50 ou mais avaliações), 74 também apresentam gênero ação (61.16%). A combinação representa 2.03% da amostra e possui lift 2.40, logo ocorre acima do que seria esperado pela frequência geral do consequente.
18	{genero_crime, periodo_2000_2009} → {genero_suspense}	Que padrão foi encontrado entre gênero crime e lançamento entre 2000 e 2009 e gênero suspense?	Entre os 198 filmes com gênero crime e lançamento entre 2000 e 2009, 114 também apresentam gênero suspense (57.58%). A combinação representa 3.12% da amostra e possui lift 2.36, logo ocorre acima do que seria esperado pela frequência geral do consequente.
19	{avaliacao_media, genero_terror} → {genero_suspense}	Que padrão foi encontrado entre avaliação média intermediária (de 3,0 a menos de 4,0) e gênero terror e gênero suspense?	Entre os 154 filmes com avaliação média intermediária (de 3,0 a menos de 4,0) e gênero terror, 87 também apresentam gênero suspense (56.49%). A combinação representa 2.38% da amostra e possui lift 2.32, logo ocorre acima do que seria esperado pela frequência geral do consequente.
20	{genero_crime, periodo_1990_1999} → {genero_suspense}	Que padrão foi encontrado entre gênero crime e lançamento entre 1990 e 1999 e gênero suspense?	Entre os 153 filmes com gênero crime e lançamento entre 1990 e 1999, 86 também apresentam gênero suspense (56.21%). A combinação representa 2.36% da amostra e possui lift 2.30, logo ocorre acima do que seria esperado pela frequência geral do consequente.
21	{avaliacao_media, genero_crime} → {genero_suspense}	Que padrão foi encontrado entre avaliação média intermediária (de 3,0 a menos de 4,0) e gênero crime e gênero suspense?	Entre os 347 filmes com avaliação média intermediária (de 3,0 a menos de 4,0) e gênero crime, 191 também apresentam gênero suspense (55.04%). A combinação representa 5.23% da amostra e possui lift 2.26, logo ocorre acima do que seria esperado pela frequência geral do consequente.
22	{genero_crime, genero_drama} → {genero_suspense}	Que padrão foi encontrado entre gênero crime e gênero drama e gênero suspense?	Entre os 269 filmes com gênero crime e gênero drama, 148 também apresentam gênero suspense (55.02%). A combinação representa 4.06% da amostra e possui lift 2.26, logo ocorre acima do que seria esperado pela frequência geral do consequente.

Continua na próxima página

Tabela 21 – continuação

Nº	Regra	Pergunta	Resposta
23	{genero_ficcao_cientifica} → {genero_acao}	Que padrão foi encontrado entre gênero ficção científica e gênero ação?	Entre os 486 filmes com gênero ficção científica, 278 também apresentam gênero ação (57.20%). A combinação representa 7.62% da amostra e possui lift 2.25, logo ocorre acima do que seria esperado pela frequência geral do consequente.
24	{avaliacao_baixa, genero_romance} → {genero_comedia}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e gênero romance e gênero comédia?	Entre os 133 filmes com avaliação média baixa (menor que 3,0) e gênero romance, 90 também apresentam gênero comédia (67.67%). A combinação representa 2.47% da amostra e possui lift 1.67, logo ocorre acima do que seria esperado pela frequência geral do consequente.
25	{avaliacao_alta, popularidade_media} → {genero_drama}	Que padrão foi encontrado entre avaliação média alta (igual ou superior a 4,0) e popularidade intermediária (10 a 49 avaliações) e gênero drama?	Entre os 190 filmes com avaliação média alta (igual ou superior a 4,0) e popularidade intermediária (10 a 49 avaliações), 136 também apresentam gênero drama (71.58%). A combinação representa 3.73% da amostra e possui lift 1.64, logo ocorre acima do que seria esperado pela frequência geral do consequente.
26	{avaliacao_alta} → {genero_drama}	Que padrão foi encontrado entre avaliação média alta (igual ou superior a 4,0) e gênero drama?	Entre os 440 filmes com avaliação média alta (igual ou superior a 4,0), 290 também apresentam gênero drama (65.91%). A combinação representa 7.95% da amostra e possui lift 1.51, logo ocorre acima do que seria esperado pela frequência geral do consequente.
27	{avaliacao_baixa, genero_drama} → {popularidade_baixa}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e gênero drama e popularidade baixa (5 a 9 avaliações)?	Entre os 185 filmes com avaliação média baixa (menor que 3,0) e gênero drama, 104 também apresentam popularidade baixa (5 a 9 avaliações) (56.22%). A combinação representa 2.85% da amostra e possui lift 1.49, logo ocorre acima do que seria esperado pela frequência geral do consequente.
28	{avaliacao_baixa, periodo_1970_1989} → {popularidade_baixa}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e lançamento entre 1970 e 1989 e popularidade baixa (5 a 9 avaliações)?	Entre os 137 filmes com avaliação média baixa (menor que 3,0) e lançamento entre 1970 e 1989, 76 também apresentam popularidade baixa (5 a 9 avaliações) (55.47%). A combinação representa 2.08% da amostra e possui lift 1.47, logo ocorre acima do que seria esperado pela frequência geral do consequente.
29	{avaliacao_baixa, genero_comedia} → {popularidade_baixa}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e gênero comédia e popularidade baixa (5 a 9 avaliações)?	Entre os 449 filmes com avaliação média baixa (menor que 3,0) e gênero comédia, 248 também apresentam popularidade baixa (5 a 9 avaliações) (55.23%). A combinação representa 6.80% da amostra e possui lift 1.46, logo ocorre acima do que seria esperado pela frequência geral do consequente.

Continua na próxima página

Tabela 21 – continuação

Nº	Regra	Pergunta	Resposta
30	{genero_ficcao_cientifica, periodo_2010_2018} → {popularidade_media}	Que padrão foi encontrado entre gênero ficção científica e lançamento entre 2010 e 2018 e popularidade intermediária (10 a 49 avaliações)?	Entre os 110 filmes com gênero ficção científica e lançamento entre 2010 e 2018, 73 também apresentam popularidade intermediária (10 a 49 avaliações) (66.36%). A combinação representa 2.00% da amostra e possui lift 1.33, logo ocorre acima do que seria esperado pela frequência geral do consequente.

Fonte: elaboração própria a partir da base *movie_recomm*.

14 Síntese da base *movie_recomm*

A análise da base *movie_recomm* percorreu todas as etapas previstas: compreensão do banco, preparação, análise exploratória, definição da transação, execução do FP-Growth, auditoria das regras e elaboração das 30 perguntas em formato tabular.

Os resultados mostraram associações entre gêneros, períodos de lançamento, avaliação média e popularidade. Algumas refletem a forma como os filmes são classificados editorialmente; outras apontam concentrações temporais ou combinações de gêneros que aparecem com frequência acima do esperado. Em todos os casos, os padrões se referem ao catálogo analisado e não devem ser entendidos como relações de causa e efeito.

15 Comparação entre as bases

Como os bancos representam fenômenos diferentes, não seria adequado usar a mesma unidade transacional nos dois casos. Na F1, cada transação corresponde ao resultado de um piloto em uma corrida e reúne largada, resultado e equipe. Na base *movie_recomm*, cada transação corresponde a um filme e reúne gêneros, período de lançamento, avaliação e popularidade.

Tabela 22 – Comparação dos experimentos de mineração

Experimento	Transações	Itens	Itemsets	Regras iniciais	Parâmetros principais
F1 completa	24.966	27	61	9	Apriori; suporte 2%; confiança 60%
F1, 1950–1959	1.939	13	48	17	Apriori; suporte 2%; confiança 60%
F1, 2014–2024	4.392	17	73	21	Apriori; suporte 2%; confiança 60%
<i>movie_recomm</i>	3.649	31	501	121	FP-Growth; suporte 2%; confiança 55%; lift inicial 1,10 e final 1,30

Fonte: elaboração própria.

Nos dois bancos, as variáveis numéricas precisaram ser convertidas em faixas. Na F1, posições e pontos foram resumidos em categorias de desempenho. Nos filmes, média, quantidade de avaliações e ano de lançamento foram discretizados. Essa simplificação torna as regras mais legíveis, mas também elimina parte dos detalhes originais e precisa ser considerada na interpretação.

O mesmo suporte percentual representa volumes bem diferentes. Um suporte de 2% corresponde a cerca de 500 resultados na F1 completa, 39 nos anos 1950, 88 na era híbrida e 73 filmes na base cinematográfica. Portanto, duas regras com o mesmo suporte relativo podem ter alcances absolutos bastante diferentes.

Na F1, as regras refletem a hierarquia esportiva. Algumas são esperadas, como a relação entre largar na frente e vencer, enquanto os recortes históricos revelam associações ligadas a equipes e períodos específicos. Na base de filmes, surgem muitas combinações entre gêneros e atributos agregados. Parte delas também é previsível, principalmente quando envolve gêneros próximos, o que justificou a filtragem por lift, redundância e utilidade.

As limitações também mudam de um banco para o outro. Na F1, regulamentos, sistemas de pontuação e ciclos de domínio das equipes dificultam a comparação direta entre épocas. Além disso, Equipe_Outras reúne organizações muito diferentes. Nos filmes, o catálogo é concentrado em determinados períodos, produções populares recebem mais avaliações e os gêneros são rótulos editoriais que podem aparecer em conjunto.

16 Conclusão

O trabalho percorreu as etapas de compreensão, preparação, análise exploratória, modelagem transacional, extração e avaliação crítica das regras em dois bancos da coleção Spider 2.0. Os resultados reforçam que a qualidade da mineração não depende apenas do algoritmo: as escolhas feitas na preparação, na discretização e na definição das transações têm influência direta sobre o que será encontrado.

Na F1, a divisão por períodos ajudou a separar relações presentes ao longo de toda a história de padrões específicos de cada era. O uso do lift mostrou que uma confiança alta pode ser enganosa quando o consequente já é muito comum. Na base *movie_recomm*, a retirada de regras óbvias, fracas e redundantes tornou o conjunto final mais claro e útil para interpretação.

O relatório reúne 45 perguntas e respostas, sendo 15 da base F1 e 30 da base de filmes. Esse total supera o mínimo solicitado no enunciado sem ampliar artificialmente a quantidade de regras. Em todas as análises, as associações foram tratadas como coocorrências e não como relações causais. A comparação entre os dois bancos mostra que regras de associação podem ser aplicadas a domínios distintos, desde que a unidade transacional faça sentido, os parâmetros sejam justificados e as limitações sejam apresentadas com clareza.

Referências

AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules. In: *Proceedings of the 20th International Conference on Very Large Data Bases*. [S.l.]: Morgan Kaufmann, 1994. p. 487–499.

HAN, J.; PEI, J.; YIN, Y. Mining frequent patterns without candidate generation. In: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*. [S.l.]: ACM, 2000. p. 1–12.

HARPER, F. M.; KONSTAN, J. A. The movielens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems*, v. 5, n. 4, p. 1–19, 2015.