

IFG - Campûs Anápolis
Ciência da Computação

Filipe Divino Silva de Azevedo
Ismael Vitor Rodrigues Pimentel

Mineração de Dados
SPIDER 2.0

Anápolis - GO
2026

Filipe Divino Silva de Azevedo
Ismael Vitor Rodrigues Pimentel

Mineração de Dados
SPIDER 2.0

Trabalho apresentado à disciplina de Mineração
de Dados como requisito parcial de avaliação do
período letivo 2026.1.

IFG - Campûs Anápolis
Ciência da Computação

Orientador: Sérgio Daniel Carvalho Canuto

Anápolis - GO
2026

Resumo

Este relatório apresenta a aplicação de técnicas de mineração de dados em dois bancos da coleção Spider 2.0: a base F1, pertencente ao domínio do automobilismo, e a base *movie_recomm*, pertencente ao domínio cinematográfico e de sistemas de recomendação. Em ambos os bancos foram realizadas compreensão estrutural, preparação, tratamento de qualidade, caracterização exploratória, transformação para o formato transacional e extração de regras de associação. Na base F1, cada transação representou o resultado de um piloto em uma corrida e reuniu categoria de largada, resultado e equipe. O Apriori foi aplicado à série completa e aos períodos 1950–1959 e 2014–2024, produzindo, respectivamente, 9, 17 e 21 regras sob suporte mínimo de 2% e confiança mínima de 60%. A auditoria pelo lift mostrou que parte das regras iniciais dos anos 1950 não representava associação positiva e deveria ser descartada. Na base de filmes, 3.649 produções foram representadas por gêneros, período de lançamento, faixa de avaliação e popularidade. O FP-Growth produziu 501 itemsets frequentes e 121 regras após os filtros iniciais, das quais 30 foram selecionadas após controle de lift, redundância e obviedade. A comparação evidencia que a definição da unidade transacional, o período histórico, o desbalanceamento e a semântica dos atributos influenciam diretamente as regras. Ao todo, foram organizadas 45 perguntas e respostas interpretativas, sem atribuir causalidade às coocorrências observadas.

Palavras-chave: mineração de dados; regras de associação; Apriori; FP-Growth; Fórmula 1; MovieLens.

Abstract

This report presents the application of data-mining techniques to two Spider 2.0 databases: F1, from the motorsport domain, and *movie_recomm*, from the movie and recommender-systems domain. Both databases underwent structural understanding, preparation, quality treatment, exploratory characterization, transaction modeling, and association-rule extraction. In the F1 database, each transaction represented a driver's result in a race and combined starting-grid category, result category, and team. Apriori was applied to the complete series and to the 1950–1959 and 2014–2024 periods, yielding 9, 17, and 21 rules, respectively, with 2% minimum support and 60% minimum confidence. Lift auditing showed that part of the early-period rules did not represent positive associations and should be discarded. In the movie database, 3,649 productions were represented by genres, release period, rating range, and popularity. FP-Growth produced 501 frequent itemsets and 121 rules after the initial filters, of which 30 were selected after controlling lift, redundancy, and obviousness. The comparison shows that transaction definition, historical period, imbalance, and attribute semantics directly affect the extracted rules. In total, 45 interpretive questions and answers were organized without assigning causality to the observed co-occurrences.

Keywords: data mining; association rules; Apriori; FP-Growth; Formula 1; MovieLens.

Lista de ilustrações

Figura 1 – Evolução da Fórmula 1 ao longo das temporadas	13
Figura 2 – Grandes Prêmios disputados por equipe	14
Figura 3 – Taxa de vitória por equipe	14
Figura 4 – Nacionalidade dos pilotos vencedores	15
Figura 5 – Equipe com maior número de vitórias em cada década	16
Figura 6 – Distribuição da pontuação obtida pelos pilotos	17
Figura 7 – Boxplot da posição de largada	17
Figura 8 – Boxplot da pontuação obtida	18
Figura 9 – Matriz de correlação das variáveis numéricas da base F1	19
Figura 10 – Distribuição das notas atribuídas pelos usuários	32
Figura 11 – Distribuição das médias de avaliação dos filmes	32
Figura 12 – Distribuição da quantidade de avaliações entre os filmes preparados	33
Figura 13 – Boxplot da média de avaliações entre os filmes preparados	34
Figura 14 – Boxplot da quantidade de avaliações entre os filmes preparados	34
Figura 15 – Gêneros mais frequentes entre os filmes preparados	35
Figura 16 – Quantidade de filmes por período de lançamento	36
Figura 17 – Matriz de correlação das variáveis numéricas entre os filmes preparados . . .	37

Lista de tabelas

Tabela 1 – Tabelas principais da base F1	11
Tabela 2 – Resumo dos experimentos de regras na base F1	20
Tabela 3 – Regras da base completa da Fórmula 1 (1950–2024)	20
Tabela 4 – Regras representativas da era híbrida (2014–2024)	21
Tabela 5 – Regras positivas das primeiras temporadas (1950–1959)	22
Tabela 6 – Auditoria crítica das regras da base F1	23
Tabela 7 – Perguntas e respostas derivadas das regras da base F1	24
Tabela 8 – Tabelas principais da base <i>movie_recomm</i>	27
Tabela 9 – Relacionamentos relevantes entre as tabelas	28
Tabela 10 – Atributos selecionados e suas finalidades	29
Tabela 11 – Resumo da qualidade dos dados	30
Tabela 12 – Variáveis derivadas e critérios de discretização	30
Tabela 13 – Estatísticas descritivas das variáveis principais	31
Tabela 14 – Possíveis valores extremos segundo o intervalo interquartil	33
Tabela 15 – Gêneros mais frequentes entre os filmes preparados	35
Tabela 16 – Distribuição das faixas discretizadas	36
Tabela 17 – Parâmetros utilizados na extração das regras	39
Tabela 18 – Resultados do processo de extração e filtragem	39
Tabela 19 – Exemplos de regras auditadas e decisões de filtragem	41
Tabela 20 – Discussão crítica de regras representativas	41
Tabela 21 – Perguntas e respostas derivadas das regras de associação	43
Tabela 22 – Comparação dos experimentos de mineração	49

Lista de abreviaturas e siglas

CSV	<i>Comma-Separated Values</i>
EDA	Análise Exploratória de Dados
F1	Fórmula 1
FP-Growth	<i>Frequent Pattern Growth</i>
IQR	Intervalo interquartil

Sumário

1	Introdução	9
I	Base de Fórmula 1	10
2	Compreensão da base F1	11
2.1	Nome e domínio	11
2.2	Estrutura da base	11
3	Preparação dos dados da base F1	12
3.1	Seleção e qualidade dos dados	12
3.2	Discretização e transações	12
4	Caracterização exploratória da base F1	13
4.1	Evolução histórica	13
4.2	Participação e desempenho das equipes	13
4.3	Nacionalidades e domínio por década	15
4.4	Distribuição, correlação e valores extremos	16
5	Modelagem e extração das regras da base F1	20
5.1	Estratégia e parâmetros	20
5.2	Base completa: 1950–2024	20
5.3	Era híbrida: 2014–2024	21
5.4	Primeiras temporadas: 1950–1959	22
6	Análise crítica e perguntas da base F1	23
6.1	Auditoria das regras	23
6.2	Perguntas e respostas	23
II	Base <i>Movie Recommendation Database</i>	26
7	Compreensão da base escolhida	27
7.1	Nome e domínio da base	27
7.2	Tabelas analisadas	27
7.3	Tipos de atributos	28
7.4	Relacionamentos relevantes	28
7.5	Justificativa da seleção	28
8	Preparação dos dados	29
8.1	Seleção das tabelas e dos atributos	29
8.2	Qualidade e integridade dos dados	29
8.3	Agregação e criação de variáveis	30
9	Caracterização exploratória dos dados	31

9.1	Distribuição das avaliações	31
9.2	Popularidade e valores extremos	32
9.3	Frequência dos gêneros e dos períodos	35
9.4	Correlações	36
10	Modelagem da estratégia para extração de regras	38
11	Extração das regras de associação	39
12	Análise crítica das regras relevantes	41
12.1	Regras óbvias, redundantes ou pouco úteis	41
12.2	Discussão de regras representativas	41
13	Perguntas e respostas derivadas das regras	43
14	Síntese da base <i>movie_recomm</i>	48
15	Comparação entre as bases	49
16	Conclusão	50
Referências		51

1 Introdução

O trabalho aplica técnicas de mineração de dados a dois bancos relacionais da coleção Spider 2.0. Foram escolhidas as bases F1 e *movie_recomm*, pertencentes a domínios distintos. A primeira registra eventos históricos do Campeonato Mundial de Fórmula 1; a segunda reúne filmes e avaliações de usuários do conjunto MovieLens.

O objetivo é compreender a estrutura dos bancos, preparar e caracterizar os dados, definir unidades transacionais coerentes, extrair regras de associação e discutir criticamente sua relevância. A comparação entre os bancos permite observar como a semântica dos atributos, o volume de registros, a discretização e o desbalanceamento afetam os padrões encontrados.

Na base F1 foi utilizado o algoritmo Apriori, proposto para identificar conjuntos frequentes e gerar regras a partir de suporte e confiança (AGRAWAL; SRIKANT, 1994). Na base de filmes foi empregado o FP-Growth, que encontra padrões frequentes sem gerar explicitamente todos os candidatos do Apriori (HAN; PEI; YIN, 2000). As tabelas MovieLens utilizadas são descritas por Harper e Konstan (2015).

Parte I

Base de Fórmula 1

2 Compreensão da base F1

2.1 Nome e domínio

A base F1 pertence ao domínio do automobilismo e reúne informações históricas do Campeonato Mundial de Fórmula 1. Os dados abrangem pilotos, equipes, circuitos, corridas, classificações, resultados, tempos de volta, paradas nos boxes e temporadas.

2.2 Estrutura da base

A análise considerou 15 tabelas principais, desconsiderando tabelas auxiliares, tabelas de estágio e estatísticas previamente agregadas.

Tabela 1 – Tabelas principais da base F1

Tabela	Descrição	Registros	Atributos
circuits	Circuitos das corridas.	77	9
constructor_results	Resultados das equipes em cada corrida.	12.545	5
constructor_standings	Classificação das equipes.	13.311	7
constructors	Cadastro das equipes.	212	5
driver_standings	Classificação dos pilotos.	34.680	7
drivers	Cadastro dos pilotos.	860	9
lap_times	Tempos de volta.	580.619	6
pit_stops	Paradas nos boxes.	11.120	7
position_descriptions	Descrição das posições.	6	2
qualifying	Resultados da classificação.	10.334	9
races	Informações das corridas.	1.125	18
results	Resultado final dos pilotos.	26.599	18
seasons	Temporadas.	75	2
sprint_results	Resultados das corridas sprint.	300	16
status	Situação final dos pilotos.	139	2

Fonte: elaboração própria a partir da base F1.

Os atributos encontrados são dos tipos INTEGER, DOUBLE, VARCHAR e DATE. Os relacionamentos centrais utilizam constructorId, raceId, circuitId e statusId. Para a mineração, a tabela results foi usada como entidade principal, relacionada a constructors e races. As tabelas circuits e status apoiaram a análise exploratória e a verificação da qualidade dos registros.

3 Preparação dos dados da base F1

3.1 Seleção e qualidade dos dados

Cada registro da tabela `results` corresponde ao desempenho de um piloto em uma corrida. Foram selecionados `grid`, `position`, `points`, `constructorId`, `raceId` e `statusId`; das tabelas relacionadas foram utilizados o nome da equipe, o ano, o circuito, o país e o texto do `status`.

A verificação de qualidade identificou 10.932 valores ausentes em `position`, equivalentes a 41,10% dos 26.599 resultados. Esses registros estão associados principalmente a abandonos, acidentes e problemas mecânicos, portanto foram preservados. Não foram encontradas linhas completamente duplicadas nas tabelas selecionadas. As representações *USA* e *United States* foram padronizadas quando o país foi utilizado na exploração.

Foram removidos da estratégia transacional identificadores de piloto, URLs, tempos detalhados, melhor volta e velocidade máxima, pois produziriam itens muito específicos ou pouco relacionados ao objetivo das regras.

3.2 Discretização e transações

Foram mantidos apenas resultados com posição de largada maior que zero, totalizando 24.966 transações na série completa. A posição de largada foi discretizada em `Grid_Front` (1 a 6), `Grid_Middle` (7 a 12) e `Grid_Back` (acima de 12). O resultado foi transformado em uma única categoria: `Venceu`, `Podio` para segundo ou terceiro lugar, `Pontuou`, `Nao_Pontuou` ou `Abandono`.

As 18 equipes com pelo menos 500 resultados foram preservadas individualmente; as demais foram agrupadas em `Equipe_Outras`. A transação final utilizada pelo Apriori contém exatamente três itens: categoria de largada, categoria de resultado e equipe.

```
{Grid_Front, Venceu, Equipe_Ferrari}
```


Essa definição corrige uma inconsistência do relatório preliminar, que citava temporada, circuito, país e status dentro das transações, embora os scripts finais de extração utilizassem somente `grid`, `resultado` e `equipe`.

4 Caracterização exploratória da base F1

4.1 Evolução histórica

A base abrange 75 temporadas, de 1950 a 2024, e 1.125 corridas. A quantidade anual de provas aumentou de aproximadamente sete etapas nas primeiras temporadas para 24 em 2024. A redução de 2020 representa uma anomalia temporal coerente com as restrições daquele ano.

Figura 1 – Evolução da Fórmula 1 ao longo das temporadas




Fonte: elaboração própria a partir da base F1.

4.2 Participação e desempenho das equipes


Ferrari, McLaren e Williams apresentam o maior número de Grandes Prêmios disputados. Como o tempo de participação é muito desigual, a análise também considerou a taxa de vitória entre equipes com pelo menos cem corridas.

Figura 2 – Grandes Prêmios disputados por equipe



Fonte: elaboração própria a partir da base F1.

Figura 3 – Taxa de vitória por equipe




Fonte: elaboração própria a partir da base F1. Foram consideradas equipes com pelo menos cem Grandes Prêmios.

A Mercedes apresenta a maior taxa de vitória no recorte, seguida por Red Bull, Ferrari e McLaren. O indicador relativo evita concluir que a equipe com mais vitórias absolutas seja necessariamente a mais eficiente em relação à quantidade de participações.

4.3 Nacionalidades e domínio por década


Pilotos britânicos concentram o maior número de vitórias, seguidos por alemães e brasileiros. A análise por década mostra alternância do domínio: Ferrari nas décadas de 1950, 1970 e 2000; Lotus-Climax nos anos 1960; McLaren nos anos 1980; Williams nos anos 1990; Mercedes nos anos 2010; e Red Bull nos anos 2020.

Figura 4 – Nacionalidade dos pilotos vencedores



Fonte: elaboração própria a partir da base F1.

Figura 5 – Equipe com maior número de vitórias em cada década




Fonte: elaboração própria a partir da base F1.

A alternância histórica justifica a realização de experimentos separados. Uma única extração sobre 75 temporadas tende a priorizar padrões gerais e a ocultar associações específicas de cada era.

4.4 Distribuição, correlação e valores extremos


A posição de largada possui mediana 12 e intervalo interquartil de 6 a 17. Apenas um registro, com grid 34, ultrapassa o limite superior de 33,5 calculado pelo método do IQR. A pontuação apresenta mediana zero e forte assimetria à direita: 16.889 dos 24.966 resultados com grid válido possuem zero ponto. Pelo IQR, valores acima de cinco pontos são classificados como extremos, totalizando 3.813 registros. Esses valores são plausíveis e refletem o sistema de pontuação, incluindo resultados de alta pontuação e a prova com pontuação dobrada de 2014.

Figura 6 – Distribuição da pontuação obtida pelos pilotos




Fonte: elaboração própria a partir da base F1.

Figura 7 – Boxplot da posição de largada



Fonte: elaboração própria a partir da base F1.


Figura 8 – Boxplot da pontuação obtida



Fonte: elaboração própria a partir da base F1.

A matriz de correlação apresenta correlação positiva de 0,64 entre grid e posição final. Como números menores representam melhores colocações, o sinal positivo significa que pilotos que largam em posições numericamente baixas tendem a terminar em posições também baixas. A posição final possui correlação -0,65 com os pontos e o grid apresenta correlação -0,55 com a pontuação.

Figura 9 – Matriz de correlação das variáveis numéricas da base F1



Fonte: elaboração própria a partir da base F1.

5 Modelagem e extração das regras da base F1

5.1 Estratégia e parâmetros

Foi adotada a estratégia de uma transação por resultado de piloto em corrida. O Apriori foi executado com suporte mínimo de 0,02 e confiança mínima de 0,60. Os mesmos parâmetros foram aplicados à base completa, às temporadas 1950–1959 e ao período 2014–2024, permitindo comparar os experimentos.

Tabela 2 – Resumo dos experimentos de regras na base F1

Período	Transações	Itens	Itemsets	Regras	Ocorrências mínimas
1950–2024	24.966	27	61	9	aproximadamente 500
1950–1959	1.939	13	48	17	aproximadamente 39
2014–2024	4.392	17	73	21	aproximadamente 88

Fonte: elaboração própria. Regras contabilizadas com confiança mínima de 60%.

A confiança mínima, isoladamente, não garante associação positiva. Por isso, o lift foi recalculado e utilizado na análise crítica. Nas primeiras temporadas, somente nove das 17 regras apresentaram lift igual ou superior a 1,10.

5.2 Base completa: 1950–2024

Tabela 3 – Regras da base completa da Fórmula 1 (1950–2024)

Regra	Suporte	Confiança	Lift	Interpretação
{Venceu} → {Grid_Front}	4,15%	92,50%	3.43	A vitória aparece fortemente associada às seis primeiras posições de largada. É um padrão esperado, útil principalmente como validação da estratégia transacional.
{Podio} → {Grid_Front}	6,78%	75,13%	2.79	Resultados de segundo ou terceiro lugar concentram-se entre pilotos que largaram na parte dianteira do grid.
{Equipe_Ferrari} → {Grid_Front}	6,16%	64,03%	2.37	A Ferrari aparece historicamente associada às primeiras posições de largada, refletindo sua presença prolongada entre as equipes competitivas.
{Equipe_Minardi} → {Grid_Back}	2,42%	94,23%	2.05	A Minardi apresenta concentração muito elevada no fundo do grid. O suporte é menor, pois a equipe participou de apenas parte da série histórica.

Tabela 3 – continuação

Regra	Suporte	Confiança	Lift	Interpretação
{Nao_Pontuou, Equipe_Outras} → {Grid_Back}	10,60%	74,96%	1.63	Entre equipes agrupadas como outras, a ausência de pontuação ocorre frequentemente após largadas no fundo do grid.
{Nao_Pontuou} → {Grid_Back}	20,90%	69,14%	1.50	A ausência de pontuação está associada ao fundo do grid, mas a relação não deve ser interpretada como causalidade.
{Abandono, Equipe_Outras} → {Grid_Back}	10,46%	64,87%	1.41	Abandonos de equipes menos frequentes aparecem associados às últimas posições de largada; o agrupamento heterogêneo exige cautela.
{Equipe_Tyrrell} → {Grid_Back}	2,11%	62,29%	1.35	A associação resume o desempenho agregado da Tyrrell em toda a série, mas pode ocultar fases historicamente distintas da equipe.
{Equipe_Outras} → {Grid_Back}	22,89%	60,32%	1.31	O agrupamento de equipes de menor frequência concentra largadas no fundo do grid; a regra é abrangente, porém pouco específica.

Fonte: elaboração própria a partir da base F1.

5.3 Era híbrida: 2014–2024

Tabela 4 – Regras representativas da era híbrida (2014–2024)

Regra	Suporte	Confiança	Lift	Interpretação
{Equipe_Mercedes, Venceu} → {Grid_Front}	2,57%	98,26%	3.27	Quase todas as vitórias da Mercedes na era híbrida ocorreram após largadas entre as seis primeiras posições.
{Venceu} → {Grid_Front}	4,80%	95,91%	3.20	Na era híbrida, a relação entre vitória e largada na frente tornou-se ainda mais forte do que na série completa.
{Equipe_Ferrari, Podio} → {Grid_Front}	2,50%	94,02%	3.13	Os pódios da Ferrari no período moderno aparecem quase sempre precedidos por largadas na frente.
{Equipe_Mercedes} → {Grid_Front}	8,33%	83,37%	2.78	A Mercedes esteve fortemente concentrada nas primeiras posições do grid entre 2014 e 2024.
{Equipe_Red Bull} → {Grid_Front}	6,94%	71,10%	2.37	A Red Bull também apresenta associação expressiva com largadas dianteiras no período moderno.
{Equipe_Sauber, Nao_Pontuou} → {Grid_Back}	3,10%	91,28%	2.28	Quando a Sauber não pontuou, em mais de 91% dos casos analisados largou no fundo do grid.
{Equipe_Williams, Grid_Back} → {Nao_Pontuou}	4,42%	72,66%	2.10	Largadas da Williams no fundo do grid estiveram associadas à ausência de pontuação na era híbrida.
{Equipe_Ferrari, Pontuou} → {Grid_Front}	3,01%	62,86%	2.09	Parte relevante das corridas em que a Ferrari pontuou foi iniciada entre as primeiras posições.
{Equipe_Sauber, Grid_Back} → {Nao_Pontuou}	3,10%	70,10%	2.02	A combinação Sauber e fundo do grid aumenta significativamente a ocorrência de resultados sem pontos.
{Equipe_Outras, Grid_Front} → {Pontuou}	2,16%	67,86%	1.95	Mesmo equipes agrupadas como outras pontuaram com frequência quando conseguiram largar na frente.

Tabela 4 – continuação

Regra	Suporte	Confiança	Lift	Interpretação
{Grid_Back, Equipe_Outras} → {Nao_Pontuou}	12,75%	66,59%	1.92	Equipes menos frequentes que largaram no fundo do grid terminaram sem pontos em cerca de dois terços dos registros.
{Grid_Back} → {Nao_Pontuou}	24,89%	62,10%	1.79	No período moderno, largar no fundo do grid esteve positivamente associado a não pontuar.

Fonte: elaboração própria a partir da base F1.

5.4 Primeiras temporadas: 1950–1959

Tabela 5 – Regras positivas das primeiras temporadas (1950–1959)

Regra	Suporte	Confiança	Lift	Interpretação
{Venceu} → {Grid_Front}	3,92%	87,36%	3.17	A associação entre vitória e largada dianteira já era forte nas primeiras temporadas.
{Equipe_Ferrari, Podio} → {Grid_Front}	3,40%	75,86%	2.75	Os pódios da Ferrari nos anos 1950 estiveram concentrados nas primeiras posições do grid.
{Podio} → {Grid_Front}	6,29%	65,59%	2.38	Mesmo no início da categoria, segundo e terceiro lugares apresentavam associação positiva com largadas na frente.
{Nao_Pontuou, Equipe_Outras} → {Grid_Back}	15,21%	65,41%	1.47	Entre equipes agrupadas como outras, resultados sem pontos apareceram associados ao fundo do grid.
{Nao_Pontuou} → {Grid_Back}	16,97%	60,70%	1.37	A ausência de pontuação já se concentrava nas últimas posições de largada, embora com força menor que na era moderna.
{Nao_Pontuou, Grid_Back} → {Equipe_Outras}	15,21%	89,67%	1.20	A confiança é alta, mas o lift é moderado porque o item Equipe_Outras é muito frequente nos anos 1950.
{Grid_Back} → {Equipe_Outras}	39,35%	88,72%	1.18	A maioria das largadas no fundo pertencia ao agrupamento de equipes menos frequentes; o resultado é influenciado pelo tamanho desse grupo.
{Abandono, Grid_Back} → {Equipe_Outras}	21,66%	88,24%	1.18	Abandonos no fundo do grid concentraram-se em equipes agrupadas como outras, possivelmente refletindo menor competitividade e confiabilidade.
{Nao_Pontuou} → {Equipe_Outras}	23,26%	83,21%	1.11	A associação é positiva, porém próxima do limite adotado e fortemente condicionada pela frequência elevada do agrupamento.

Fonte: elaboração própria a partir da base F1.

6 Análise crítica e perguntas da base F1

6.1 Auditoria das regras

Tabela 6 – Auditoria crítica das regras da base F1

Regra ou grupo	Classificação	Discussão
{Venceu} → {Grid_Front}	Esperada, mas válida	A regra possui lift superior a 3 nos três experimentos. Embora pouco surpreendente, confirma que a transformação dos dados preservou uma relação esportiva central.
{Podio} → {Grid_Front}	Esperada	Também funciona como regra de validação. Sua força aumenta na era híbrida, indicando maior concentração do desempenho entre equipes de ponta.
Regras envolvendo Mercedes, Red Bull, Sauber e Williams	Específicas do período	São mais informativas do que as regras gerais porque descrevem padrões característicos de 2014–2024. Não devem ser extrapoladas para toda a história.
Regras com Equipe_Outras	Sensíveis ao agrupamento	O item reúne equipes heterogêneas. Nos anos 1950, ele aparece em grande parte das transações, elevando a confiança de regras cujo lift é apenas moderado.
Regras de 1950–1959 com lift inferior a 1,10	Descartadas	Das 17 regras geradas por suporte e confiança, oito não atingiram lift 1,10; seis possuíam lift inferior a 1, indicando ausência de associação positiva. Elas não foram usadas nas perguntas finais.
{Pontuou} → {Equipe_Outras} nos anos 1950	Não relevante	Apesar da confiança de 65,41%, o lift foi 0,87. O consequente era tão frequente que a regra ocorria menos do que o esperado sob independência.
Relações entre grid e resultado	Coocorrência, não causa	Largar na frente está associado a melhores resultados, mas as regras não isolam fatores como desempenho do carro, habilidade do piloto, estratégia ou confiabilidade.
Mudanças no sistema de pontuação	Limitação histórica	A categoria Pontuou reduz diferenças entre regulamentos, porém não elimina completamente o efeito das mudanças ocorridas ao longo de 75 temporadas.

Fonte: elaboração própria.

A comparação entre os experimentos mostra que as regras gerais envolvendo vitória, pódio e grid aparecem em todos os períodos. As regras específicas de equipes são mais informativas, mas dependem do recorte histórico. Os resultados dos anos 1950 são especialmente sensíveis ao agrupamento Equipe_Outras, que representa grande parte das transações.

6.2 Perguntas e respostas

Foram selecionadas 15 perguntas não redundantes, distribuídas entre a série completa, a era híbrida e as primeiras temporadas. As regras descartadas por lift insuficiente não foram utilizadas.

Tabela 7 – Perguntas e respostas derivadas das regras da base F1

Nº	Regra	Pergunta	Resposta
1	{Venceu} → {Grid_Front}	Por que as vitórias aparecem associadas às primeiras posições do grid?	Na série completa, 1.036 das 1.120 vitórias analisadas ocorreram após largadas entre as seis primeiras posições, resultando em confiança de 92,50% e lift 3,43. A regra indica coocorrência forte, mas não prova causalidade.
2	{Podio} → {Grid_Front}	Por que os pódios aparecem frequentemente ligados à parte dianteira do grid?	Dos 2.252 resultados classificados como segundo ou terceiro lugar, 1.692 partiram da frente do grid. A confiança de 75,13% e o lift 2,79 mostram associação consistente ao longo da história.
3	{Equipe_Ferrari} → {Grid_Front}	O que a regra revela sobre a Ferrari na série histórica?	Entre 2.402 resultados da Ferrari com posição de largada válida, 1.538 ocorreram nas seis primeiras posições. O padrão possui confiança de 64,03% e lift 2,37.
4	{Equipe_Minardi} → {Grid_Back}	Por que a Minardi aparece fortemente associada ao fundo do grid?	Dos 641 resultados da Minardi, 604 partiram após a 12ª posição. A confiança de 94,23% e o lift 2,05 evidenciam concentração histórica nas últimas posições.
5	{Nao_Pontuou} → {Grid_Back}	Existe associação entre não pontuar e largar no fundo do grid?	Sim. Na base completa, 5.218 dos 7.547 resultados sem pontuação partiram do fundo do grid. A confiança foi 69,14% e o lift 1,50.
6	{Equipe_Mercedes, Venceu} → {Grid_Front}	Como ocorreram as vitórias da Mercedes entre 2014 e 2024?	No período, 113 das 115 vitórias da Mercedes partiram das seis primeiras posições. A confiança de 98,26% e o lift 3,27 indicam associação muito forte.
7	{Equipe_Mercedes} → {Grid_Front}	A Mercedes largou frequentemente na frente durante a era híbrida?	Sim. Dos 439 resultados da equipe no recorte, 366 partiram da frente do grid, com confiança de 83,37% e lift 2,78.
8	{Equipe_Red Bull} → {Grid_Front}	Qual padrão foi encontrado para a Red Bull no período moderno?	Entre 429 resultados da Red Bull, 305 ocorreram nas seis primeiras posições de largada. A confiança foi 71,10% e o lift 2,37.
9	{Equipe_Sauber, Nao_Pontuou} → {Grid_Back}	Quando a Sauber não pontuou, de onde normalmente largou?	Em 136 dos 149 casos sem pontuação, a Sauber largou no fundo do grid. A confiança alcançou 91,28% e o lift 2,28.
10	{Equipe_Williams, Grid_Back} → {Nao_Pontuou}	O que ocorreu quando a Williams largou no fundo do grid entre 2014 e 2024?	Das 267 ocorrências, 194 terminaram sem pontuação. A confiança de 72,66% e o lift 2,10 mostram associação relevante no período.
11	{Equipe_Outras, Grid_Front} → {Pontuou}	Equipes menos frequentes conseguiram pontuar quando largaram na frente?	Sim. Entre 140 registros do agrupamento Equipe_Outras na frente do grid, 95 terminaram com pontos. A confiança foi 67,86% e o lift 1,95.
12	{Grid_Back} → {Nao_Pontuou}	Na era híbrida, largar no fundo esteve associado a não pontuar?	Dos 1.760 resultados iniciados após a 12ª posição, 1.093 terminaram sem pontos. A confiança foi 62,10% e o lift 1,79.
13	{Equipe_Ferrari, Podio} → {Grid_Front}	Como foram os pódios da Ferrari nas primeiras temporadas?	Entre 87 pódios da Ferrari nos anos 1950, 66 partiram da frente do grid. A confiança foi 75,86% e o lift 2,75.

Continua na próxima página

Tabela 7 – continuação

Nº	Regra	Pergunta	Resposta
14	{Nao_Pontuou, Grid_Back} → {Equipe_Outras}	Por que resultados sem pontos no fundo do grid aparecem ligados a Equipe_Outras nos anos 1950?	Dos 329 registros com essa combinação, 295 pertenciam ao agrupamento. A confiança foi 89,67%, mas o lift de 1,20 exige cautela porque Equipe_Outras era muito frequente.
15	{Abandono, Grid_Back} → {Equipe_Outras}	O que a associação entre abandono, fundo do grid e equipes agrupadas indica?	Nos anos 1950, 420 dos 476 abandonos ocorridos no fundo do grid pertenciam a Equipe_Outras. O lift 1,18 indica associação positiva moderada, influenciada pelo agrupamento.

Fonte: elaboração própria a partir da base F1.

Parte II

Base Movie Recommendation Database

7 Compreensão da base escolhida

7.1 Nome e domínio da base

A base analisada é a *Movie Recommendation Database (movie_recomm)*. Ela pertence ao domínio de cinema e sistemas de recomendação e contém informações sobre filmes, elenco, pessoas envolvidas nas produções, personagens, categorias, palavras-chave e avaliações realizadas por usuários.

As principais entidades representadas são filmes, usuários, avaliações, pessoas ligadas às produções, personagens, funções profissionais, categorias, gêneros e palavras-chave. Para a estratégia de mineração, as entidades centrais foram filme, usuário e avaliação.

7.2 Tabelas analisadas

Tabela 8 – Tabelas principais da base *movie_recomm*

Tabela	Descrição	Registros	Atributos
all_casts	Relação entre filmes, pessoas e funções desempenhadas na produção.	1.242.442	5
all_categories	Cadastro das categorias existentes na base.	15.218	3
all_characters	Cadastro dos personagens presentes nos filmes.	1.524	2
all_movie_aliases_iso	Títulos alternativos dos filmes em diferentes idiomas.	297.374	4
all_people	Cadastro das pessoas envolvidas nas produções cinematográficas.	287.868	5
category_names	Nomes das categorias em diferentes idiomas.	56.201	3
job_names	Nomes das funções exercidas na produção.	2.145	3
movie_categories	Associação entre filmes e suas categorias.	224.751	2
movie_keywords	Associação entre filmes e palavras-chave.	413.255	2
movielens_movies	Cadastro dos filmes utilizados pelo conjunto MovieLens.	9.742	3
movielens_ratings	Avaliações realizadas pelos usuários sobre os filmes.	100.836	4

Fonte: elaboração própria a partir da base *movie_recomm*.

A base é composta por 11 tabelas principais, que representam diferentes entidades relacionadas ao domínio cinematográfico e à recomendação de filmes.

7.3 Tipos de atributos

Os atributos presentes na base estão distribuídos entre os seguintes tipos:

- INTEGER: identificadores e valores inteiros;
- DOUBLE: avaliações numéricas com casas decimais;
- VARCHAR: informações textuais, como nomes, títulos e gêneros.

7.4 Relacionamentos relevantes

Tabela 9 – Relacionamentos relevantes entre as tabelas

Tabela principal	Chave de ligação	Tabelas relacionadas
all_people	person_id	all_casts
job_names	job_id	all_casts
category_names	category_id	movie_categories e movie_keywords
all_movie_aliases_iso	movie_id	all_casts, movie_categories e movie_keywords
movielens_movies	movieId	movielens_ratings

Fonte: elaboração própria.

Embora o banco não declare todas as chaves estrangeiras explicitamente, os relacionamentos podem ser identificados pelas colunas compartilhadas. Para a mineração de regras, foi utilizado o relacionamento entre `movielens_movies` e `movielens_ratings` por meio de `movieId`.

7.5 Justificativa da seleção

A compreensão inicial considerou as 11 tabelas principais. Para as etapas de preparação e mineração, foram selecionadas `movielens_movies` e `movielens_ratings` porque possuem ligação direta, quantidade suficiente de registros e atributos adequados para estudar associações entre gêneros, período de lançamento, avaliação média e popularidade.

8 Preparação dos dados

8.1 Seleção das tabelas e dos atributos

Para as etapas de preparação, análise exploratória e extração de regras de associação, foram selecionadas as tabelas `movielens_movies` e `movielens_ratings`. A primeira contém o identificador, o título e os gêneros de 9.742 filmes. A segunda contém 100.836 avaliações realizadas por 610 usuários, incluindo o identificador do filme, a nota e o instante da avaliação.

Tabela 10 – Atributos selecionados e suas finalidades

Tabela	Atributo	Finalidade
<code>movielens_movies</code>	<code>movieId</code>	Identificação e relacionamento do filme.
<code>movielens_movies</code>	<code>title</code>	Título e extração do ano de lançamento.
<code>movielens_movies</code>	<code>genres</code>	Construção dos itens de gênero.
<code>movielens_ratings</code>	<code>userId</code>	Identificação do usuário e auditoria de duplicatas.
<code>movielens_ratings</code>	<code>movieId</code>	Relacionamento com o cadastro de filmes.
<code>movielens_ratings</code>	<code>rating</code>	Cálculo das estatísticas de avaliação.
<code>movielens_ratings</code>	<code>timestamp</code>	Conversão para data e identificação do intervalo temporal das avaliações.

Fonte: elaboração própria.

As demais tabelas representam outro subconjunto cinematográfico, com elenco, pessoas, categorias e palavras-chave, mas não possuem ligação direta documentada com os identificadores do MovieLens. Por esse motivo, não foram utilizadas nesta estratégia.

8.2 Qualidade e integridade dos dados

Não foram encontrados valores nulos nos atributos essenciais. Todas as avaliações correspondem a filmes cadastrados e não existem duplicatas da combinação `userId` e `movieId`. Foram identificados 18 filmes sem avaliação, 34 filmes com o marcador “(no genres listed)”, 13 títulos sem ano final no formato esperado e cinco pares de títulos repetidos associados a identificadores diferentes.

Os títulos repetidos não foram removidos, pois os registros possuem identificadores e, em alguns casos, classificações de gênero diferentes. Os filmes sem avaliações e sem gênero conhecido permaneceram no relatório de qualidade, mas não foram utilizados na mineração. Os textos foram normalizados, os atributos numéricos foram convertidos para tipos adequados e o `timestamp` foi convertido para data e hora.

Os gêneros foram separados pelo delimitador original, normalizados para minúsculas, sem acentos e com sublinhados, formando itens categóricos como `genero_acao` e `genero_ficcao_cientifica`.

movieId foi mantido apenas como identificador; title foi utilizado para extrair o ano; userId foi utilizado na auditoria e na agregação; e timestamp serviu para a verificação temporal, mas não entrou diretamente nas transações. A mediana não foi discretizada para as regras porque apresentou correlação muito alta com a média, evitando redundância entre atributos equivalentes.

Tabela 11 – Resumo da qualidade dos dados

Indicador	Resultado	Observação
Filmes sem avaliação	18	Mantidos somente na auditoria.
Avaliações órfãs	0	Todas possuem filme correspondente.
Duplicatas usuário-filme	0	Nenhuma duplicata encontrada.
Filmes sem gênero informado	34	Excluídos das transações.
Filmes usados nas transações	3.649	Mínimo de cinco avaliações.

Fonte: elaboração própria.

8.3 Agregação e criação de variáveis

As avaliações foram agregadas por filme. Para cada produção, foram calculadas a quantidade de avaliações, a média, a mediana, o desvio-padrão, a primeira avaliação e a última avaliação. Para reduzir a instabilidade de médias calculadas com poucas observações, foram mantidos somente filmes com pelo menos cinco avaliações e gênero conhecido. Após os filtros, permaneceram 3.649 filmes.

Tabela 12 – Variáveis derivadas e critérios de discretização

Nova variável	Definição
ano_lancamento	Ano extraído do final do título.
periodo_lancamento	Antes de 1950; 1950–1969; 1970–1989; 1990–1999; 2000–2009; 2010–2018.
faixa_avaliacao	Baixa: média menor que 3,0; intermediária: 3,0 a menor que 4,0; alta: média igual ou superior a 4,0.
faixa_popularidade	Baixa: 5–9 avaliações; intermediária: 10–49; alta: 50 ou mais.
quantidade_generos	Quantidade de gêneros associados ao filme.

Fonte: elaboração própria.

9 Caracterização exploratória dos dados

9.1 Distribuição das avaliações


As notas individuais atribuídas pelos usuários variam de 0,5 a 5,0. Considerando as 100.836 avaliações, a média geral é aproximadamente 3,50, a mediana é 3,5 e o desvio-padrão é cerca de 1,04. A nota 4,0 é a mais frequente, seguida pela nota 3,0. A Figura 10 descreve as avaliações individuais, enquanto a Figura 11 apresenta as médias calculadas por filme após o filtro de pelo menos cinco avaliações e gênero conhecido.

Tabela 13 – Estatísticas descritivas das variáveis principais

Variável	N	Média	Mediana	Desvio-padrão	Mínimo	Máximo
Avaliações individuais	100.836	3,50	3,50	1,04	0,50	5,00
Média por filme	3.649	3,35	3,43	0,59	1,06	4,90
Quantidade de avaliações por filme	3.649	24,74	14,00	30,29	5	329
Ano de lançamento	3.649	1994,85	1997	18,07	1902	2018
Quantidade de gêneros por filme	3.649	2,55	2	1,12	1	7


Fonte: elaboração própria.

Figura 10 – Distribuição das notas atribuídas pelos usuários



Fonte: elaboração própria a partir da base *movie_recomm*.

Figura 11 – Distribuição das médias de avaliação dos filmes



Fonte: elaboração própria a partir da base *movie_recomm*.

9.2 Popularidade e valores extremos

A quantidade de avaliações por filme apresenta forte assimetria. Na base completa, a mediana é três avaliações e o máximo é 329. Os gráficos desta seção utilizam os 3.649 filmes preparados, todos com pelo menos cinco avaliações. Nesse subconjunto, 1.380 filmes ficaram na

faixa de baixa popularidade, 1.819 na faixa intermediária e 450 na faixa alta. Na Figura 12, o eixo vertical está em escala logarítmica para permitir a visualização simultânea das faixas muito frequentes e das caudas raras da distribuição.


Pelo critério do intervalo interquartil, foram identificados 335 valores extremos na quantidade de avaliações, 32 na avaliação média e 85 no desvio-padrão. Esses registros não foram removidos porque representam comportamentos reais, como filmes muito populares, e são relevantes para compreender a distribuição da base.

Tabela 14 – Possíveis valores extremos segundo o intervalo interquartil

Variável	Possíveis outliers
Quantidade de avaliações	335
Média das avaliações	32
Desvio-padrão das avaliações	85


Fonte: elaboração própria.

Figura 12 – Distribuição da quantidade de avaliações entre os filmes preparados




Fonte: elaboração própria. O eixo vertical utiliza escala logarítmica.

Figura 13 – Boxplot da média de avaliações entre os filmes preparados



Fonte: elaboração própria a partir da base *movie_recomm*.

Figura 14 – Boxplot da quantidade de avaliações entre os filmes preparados



Fonte: elaboração própria a partir da base *movie_recomm*.

Os pontos abaixo do limite inferior na Figura 13 correspondem a filmes com médias excepcionalmente baixas. Na Figura 14, os numerosos pontos acima do limite superior representam

filmes muito mais avaliados do que a maioria. Como esses casos são plausíveis no domínio e não resultam de erro identificado, foram mantidos na análise.

9.3 Frequência dos gêneros e dos períodos


Os gêneros mais frequentes são drama, presente em 1.597 filmes (43,77%), comédia, em 1.479 (40,53%), ação, em 928 (25,43%), e suspense, em 890 (24,39%). Como um filme pode possuir vários gêneros, os percentuais não somam 100%.

Tabela 15 – Gêneros mais frequentes entre os filmes preparados

Gênero	Filmes	Percentual
Drama	1.597	43,77%
Comédia	1.479	40,53%
Ação	928	25,43%
Suspense	890	24,39%
Aventura	676	18,53%

Fonte: elaboração própria.


Figura 15 – Gêneros mais frequentes entre os filmes preparados



Fonte: elaboração própria a partir da base *movie_recomm*.

Os períodos com mais filmes são 2000–2009, com 1.145 registros, e 1990–1999, com 1.111. Em seguida aparecem 1970–1989, com 651, e 2010–2018, com 463. A concentração nos períodos mais recentes deve ser considerada na interpretação das regras temporais.

Figura 16 – Quantidade de filmes por período de lançamento



Fonte: elaboração própria a partir da base *movie_recomm*.

As faixas discretizadas de avaliação e popularidade são importantes para a construção das transações, porém seus gráficos reproduziam informações já apresentadas no histograma, no texto e nas tabelas. Para evitar redundância visual, seus totais foram preservados de forma compacta na Tabela 16.

Tabela 16 – Distribuição das faixas discretizadas

Faixa	Definição	Filmes	Percentual
Avaliação baixa	Média menor que 3,0	873	23,92%
Avaliação intermediária	3,0 a menor que 4,0	2.336	64,02%
Avaliação alta	Média igual ou superior a 4,0	440	12,06%
Popularidade baixa	5 a 9 avaliações	1.380	37,82%
Popularidade intermediária	10 a 49 avaliações	1.819	49,85%
Popularidade alta	50 ou mais avaliações	450	12,33%


Fonte: elaboração própria.

9.4 Correlações

A matriz de correlação foi calculada para os 3.649 filmes preparados. Ela mostra relação muito alta entre média e mediana das avaliações, aproximadamente 0,93, o que é esperado porque ambas resumem a mesma distribuição. A quantidade de avaliações possui correlação positiva fraca com a média, aproximadamente 0,26. O ano de lançamento apresenta correlação

negativa fraca com a média, aproximadamente -0,19. Essas relações descrevem associação linear e não devem ser interpretadas como causalidade. Para a construção das transações foi utilizada somente a faixa baseada na média, evitando duplicar informações muito semelhantes.

Figura 17 – Matriz de correlação das variáveis numéricas entre os filmes preparados



Fonte: elaboração própria a partir da base *movie_recomm*.

10 Modelagem da estratégia para extração de regras

Foi adotada uma transação por filme. Cada transação combina todos os gêneros associados ao filme com seu período de lançamento, sua faixa de avaliação média e sua faixa de popularidade.

```
{genero_animacao, genero_aventura, genero_infantil, periodo_1990_1999,  
avaliacao_media, popularidade_alta}
```

A estratégia reúne três abordagens previstas no trabalho: agregação por entidade, discretização de atributos numéricos e junção entre tabelas. A alternativa de criar uma transação por usuário foi descartada porque produziria apenas 610 transações e tenderia a gerar padrões muito gerais de consumo. A estratégia por filme fornece 3.649 transações e permite interpretar diretamente as características que coexistem nas produções.

Cada transação representa um filme, contém em média 5,545 itens e reúne itens de gênero, período, avaliação e popularidade.

11 Extração das regras de associação

Foi utilizado o algoritmo FP-Growth, disponível na biblioteca *mlxtend*. O algoritmo foi escolhido por identificar conjuntos frequentes sem gerar explicitamente todos os candidatos do Apriori, oferecendo boa eficiência para o conjunto de transações analisado.

Tabela 17 – Parâmetros utilizados na extração das regras

Parâmetro	Valor
Algoritmo	FP-Growth
Suporte mínimo	0,02 (2%)
Confiança mínima	0,55 (55%)
Lift mínimo da extração inicial	1,10
Lift mínimo para as regras finais	1,30
Tamanho máximo do itemset	4 itens
Máximo de itens no antecedente	2 itens
Consequente	Exatamente 1 item

Fonte: elaboração própria.

Com 3.649 transações, o suporte mínimo exige que um padrão apareça em aproximadamente 73 filmes. A confiança mínima de 55% permite recuperar associações em que o consequente ocorre na maioria dos casos do antecedente. O limite inicial de lift 1,10 foi mantido para auditar também associações fracas; para a seleção final, foi exigido lift mínimo de 1,30, garantindo que o consequente ocorra pelo menos 30% acima de sua frequência-base.

Tabela 18 – Resultados do processo de extração e filtragem

Resultado	Quantidade
Transações	3.649
Itens distintos	31
Itemsets frequentes	501
Regras após os filtros iniciais	121
Regras após remoção de extensões redundantes	85
Regras com lift igual ou superior a 1,30	38
Regras após exclusão das associações óbvias	33
Regras após controle de direções equivalentes	31
Regras selecionadas para perguntas e respostas	30

Fonte: elaboração própria.

A filtragem ocorreu em quatro níveis: remoção de extensões de antecedente que aumentavam a confiança em menos de cinco pontos percentuais; exclusão de regras finais com lift inferior a 1,30; retirada de associações semanticamente óbvias entre rótulos muito próximos; e manutenção de apenas uma direção quando regras distintas representavam a mesma combinação

total de itens. Esse procedimento reduz repetição e evita que a tabela final seja dominada por relações triviais de classificação.

12 Análise crítica das regras relevantes

As regras foram avaliadas conjuntamente por suporte, confiança e lift. A confiança isolada pode favorecer consequentes muito frequentes; por isso, o lift foi decisivo para diferenciar uma associação efetiva de um resultado provocado pela concentração das faixas intermediárias de avaliação e popularidade.

12.1 Regras óbvias, redundantes ou pouco úteis

Tabela 19 – Exemplos de regras auditadas e decisões de filtragem

Regra ou grupo	Indicador	Decisão
{animação} → {infantil}	Lift 7,53	Excluída da tabela final por ser uma associação direta entre rótulos editoriais fortemente sobrepostos.
{mistério} → {suspense}	Lift 2,75	Correta, porém com baixa novidade devido à proximidade temática amplamente conhecida.
{drama, popularidade média} → {avaliação média}	Lift 1,14	Confiança alta, mas associação apenas 14% acima da frequência-base da avaliação intermediária.
Direções alternativas de {animação, aventura, infantil}	Mesmo suporte conjunto	Foi mantida somente a direção com melhor equilíbrio de lift e confiança, evitando perguntas quase repetidas.

Fonte: elaboração própria.

As regras descartadas não são incorretas. Elas foram preservadas no arquivo de auditoria, pois ajudam a demonstrar que o algoritmo captou relações conhecidas. Contudo, não foram usadas entre as 30 perguntas porque o trabalho solicita regras mais interessantes e uma discussão explícita sobre padrões óbvios, redundantes ou pouco úteis.

12.2 Discussão de regras representativas

Tabela 20 – Discussão crítica de regras representativas

Regra	Suporte	Confiança	Lift	Discussão
{genero_imax} → {periodo_2010_2018}	2.19%	66.12%	5.21	A concentração de títulos IMAX no período mais recente é coerente com a expansão comercial do formato. O padrão pode ser influenciado pelo recorte temporal e por relançamentos catalogados.
{genero_acao, genero_fantasia} → {genero_aventura}	2.27%	74.11%	4.00	A combinação ação-fantasia associa-se a aventura muito acima do esperado. Isso caracteriza filmes de espetáculo, mas os rótulos podem ter sido atribuídos em conjunto.

Tabela 20 – continuação

Regra	Suporte	Confiança	Lift	Discussão
{genero_aventura, genero_suspense} → {genero_acao}	3.15%	85.19%	3.35	A confiança acima de 85% torna o antecedente muito informativo para ação. O suporte é baixo, porém ainda representa mais de cem filmes, sendo útil para descrever híbridos de gênero.
{avaliacao_media, genero_infantil} → {genero_aventura}	3.12%	56.72%	3.06	Entre filmes infantis com avaliação intermediária, aventura aparece mais de três vezes acima de sua frequência geral. A avaliação apenas delimita o subconjunto e não deve ser tratada como causa.
{genero_ficcao_cientifica, periodo_2010_2018} → {genero_acao}	2.25%	74.55%	2.93	Filmes recentes de ficção científica estão fortemente associados à ação, compatível com grandes produções e franquias do período. O recorte até 2018 e o perfil dos usuários podem amplificar o padrão.
{genero_aventura, genero_ficcao_cientifica} → {genero_acao}	3.67%	72.04%	2.83	A combinação aventura-ficção científica costuma assumir estrutura de ação. O lift confirma concentração acima da frequência-base, embora a proximidade temática reduza a novidade.
{genero_acao, genero_crime} → {genero_suspense}	3.59%	63.29%	2.59	A presença conjunta de ação e crime aumenta substancialmente suspense. O padrão faz sentido em narrativas criminais tensas, mas não implica que um gênero produza o outro.
{genero_aventura, periodo_2010_2018} → {genero_acao}	2.36%	64.66%	2.54	Aventura no período recente aparece ligada à ação, possivelmente pelo predomínio de blockbusters. A interpretação deve considerar o tamanho menor do período 2010–2018.
{avaliacao_baixa, genero_romance} → {genero_comedia}	2.47%	67.67%	1.67	Romances de avaliação baixa aparecem frequentemente como comédias, sugerindo concentração de comédias românticas nesse subconjunto. Pode refletir preferências dos usuários.
{genero_ficcao_cientifica, periodo_2010_2018} → {popularidade_media}	2.00%	66.36%	1.33	Ficção científica recente concentra-se na popularidade intermediária. Isso mostra que nem todo título recente alcança alta exposição e pode refletir a janela de coleta.

Fonte: elaboração própria a partir das regras filtradas.

O suporte indica a abrangência do padrão na base; a confiança expressa a proporção de ocorrências do consequente entre as transações que contêm o antecedente; e o lift compara essa proporção com a frequência geral do consequente. Nenhuma dessas métricas estabelece causalidade. Os resultados podem ser influenciados pela composição do catálogo, pelo desbalanceamento temporal, pela atribuição editorial de múltiplos gêneros e pelo filtro mínimo de avaliações.

13 Perguntas e respostas derivadas das regras

As 30 perguntas e respostas foram derivadas das regras finais filtradas. A apresentação tabular permite relacionar diretamente cada pergunta ao respectivo antecedente, consequente e interpretação no domínio cinematográfico.

Tabela 21 – Perguntas e respostas derivadas das regras de associação

Nº	Regra	Pergunta	Resposta
1	{avaliacao_media, genero_infantil} → {genero_animacao}	Que padrão foi encontrado entre avaliação média intermediária (de 3,0 a menos de 4,0) e gênero infantil e gênero animação?	Entre os 201 filmes com avaliação média intermediária (de 3,0 a menos de 4,0) e gênero infantil, 117 também apresentam gênero animação (58.21%). A combinação representa 3.21% da amostra e possui lift 9.36, logo ocorre acima do que seria esperado pela frequência geral do consequente.
2	{genero_aventura, genero_infantil} → {genero_animacao}	Que padrão foi encontrado entre gênero aventura e gênero infantil e gênero animação?	Entre os 163 filmes com gênero aventura e gênero infantil, 92 também apresentam gênero animação (56.44%). A combinação representa 2.52% da amostra e possui lift 9.07, logo ocorre acima do que seria esperado pela frequência geral do consequente.
3	{genero_imax} → {periodo_2010_2018}	Que padrão foi encontrado entre formato IMAX e lançamento entre 2010 e 2018?	Entre os 121 filmes com formato IMAX, 80 também apresentam lançamento entre 2010 e 2018 (66.12%). A combinação representa 2.19% da amostra e possui lift 5.21, logo ocorre acima do que seria esperado pela frequência geral do consequente.
4	{genero_acao, genero_fantasia} → {genero_aventura}	Que padrão foi encontrado entre gênero ação e gênero fantasia e gênero aventura?	Entre os 112 filmes com gênero ação e gênero fantasia, 83 também apresentam gênero aventura (74.11%). A combinação representa 2.27% da amostra e possui lift 4.00, logo ocorre acima do que seria esperado pela frequência geral do consequente.
5	{genero_aventura, genero_suspense} → {genero_acao}	Que padrão foi encontrado entre gênero aventura e gênero suspense e gênero ação?	Entre os 135 filmes com gênero aventura e gênero suspense, 115 também apresentam gênero ação (85.19%). A combinação representa 3.15% da amostra e possui lift 3.35, logo ocorre acima do que seria esperado pela frequência geral do consequente.
6	{avaliacao_media, genero_infantil} → {genero_aventura}	Que padrão foi encontrado entre avaliação média intermediária (de 3,0 a menos de 4,0) e gênero infantil e gênero aventura?	Entre os 201 filmes com avaliação média intermediária (de 3,0 a menos de 4,0) e gênero infantil, 114 também apresentam gênero aventura (56.72%). A combinação representa 3.12% da amostra e possui lift 3.06, logo ocorre acima do que seria esperado pela frequência geral do consequente.

Continua na próxima página

Tabela 21 – continuação

Nº	Regra	Pergunta	Resposta
7	{genero_ficcao_cientifica, periodo_2010_2018} → {genero_acao}	Que padrão foi encontrado entre gênero ficção científica e lançamento entre 2010 e 2018 e gênero ação?	Entre os 110 filmes com gênero ficção científica e lançamento entre 2010 e 2018, 82 também apresentam gênero ação (74.55%). A combinação representa 2.25% da amostra e possui lift 2.93, logo ocorre acima do que seria esperado pela frequência geral do consequente.
8	{genero_aventura, genero_ficcao_cientifica} → {genero_acao}	Que padrão foi encontrado entre gênero aventura e gênero ficção científica e gênero ação?	Entre os 186 filmes com gênero aventura e gênero ficção científica, 134 também apresentam gênero ação (72.04%). A combinação representa 3.67% da amostra e possui lift 2.83, logo ocorre acima do que seria esperado pela frequência geral do consequente.
9	{genero_acao, genero_crime} → {genero_suspense}	Que padrão foi encontrado entre gênero ação e gênero crime e gênero suspense?	Entre os 207 filmes com gênero ação e gênero crime, 131 também apresentam gênero suspense (63.29%). A combinação representa 3.59% da amostra e possui lift 2.59, logo ocorre acima do que seria esperado pela frequência geral do consequente.
10	{genero_aventura, periodo_2010_2018} → {genero_acao}	Que padrão foi encontrado entre gênero aventura e lançamento entre 2010 e 2018 e gênero ação?	Entre os 133 filmes com gênero aventura e lançamento entre 2010 e 2018, 86 também apresentam gênero ação (64.66%). A combinação representa 2.36% da amostra e possui lift 2.54, logo ocorre acima do que seria esperado pela frequência geral do consequente.
11	{genero_ficcao_cientifica, genero_suspense} → {genero_acao}	Que padrão foi encontrado entre gênero ficção científica e gênero suspense e gênero ação?	Entre os 173 filmes com gênero ficção científica e gênero suspense, 111 também apresentam gênero ação (64.16%). A combinação representa 3.04% da amostra e possui lift 2.52, logo ocorre acima do que seria esperado pela frequência geral do consequente.
12	{avaliacao_baixa, genero_aventura} → {genero_acao}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e gênero aventura e gênero ação?	Entre os 164 filmes com avaliação média baixa (menor que 3,0) e gênero aventura, 105 também apresentam gênero ação (64.02%). A combinação representa 2.88% da amostra e possui lift 2.52, logo ocorre acima do que seria esperado pela frequência geral do consequente.
13	{genero_terror, popularidade_media} → {genero_suspense}	Que padrão foi encontrado entre gênero terror e popularidade intermediária (10 a 49 avaliações) e gênero suspense?	Entre os 144 filmes com gênero terror e popularidade intermediária (10 a 49 avaliações), 88 também apresentam gênero suspense (61.11%). A combinação representa 2.41% da amostra e possui lift 2.51, logo ocorre acima do que seria esperado pela frequência geral do consequente.
14	{genero_imax} → {genero_acao}	Que padrão foi encontrado entre formato IMAX e gênero ação?	Entre os 121 filmes com formato IMAX, 76 também apresentam gênero ação (62.81%). A combinação representa 2.08% da amostra e possui lift 2.47, logo ocorre acima do que seria esperado pela frequência geral do consequente.

Continua na próxima página

Tabela 21 – continuação

Nº	Regra	Pergunta	Resposta
15	{avaliacao_baixa, genero_ficcao_cientifica} → {genero_acao}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e gênero ficção científica e gênero ação?	Entre os 146 filmes com avaliação média baixa (menor que 3,0) e gênero ficção científica, 91 também apresentam gênero ação (62.33%). A combinação representa 2.49% da amostra e possui lift 2.45, logo ocorre acima do que seria esperado pela frequência geral do consequente.
16	{genero_aventura, popularidade_alta} → {genero_acao}	Que padrão foi encontrado entre gênero aventura e popularidade alta (50 ou mais avaliações) e gênero ação?	Entre os 132 filmes com gênero aventura e popularidade alta (50 ou mais avaliações), 81 também apresentam gênero ação (61.36%). A combinação representa 2.22% da amostra e possui lift 2.41, logo ocorre acima do que seria esperado pela frequência geral do consequente.
17	{genero_suspense, popularidade_alta} → {genero_acao}	Que padrão foi encontrado entre gênero suspense e popularidade alta (50 ou mais avaliações) e gênero ação?	Entre os 121 filmes com gênero suspense e popularidade alta (50 ou mais avaliações), 74 também apresentam gênero ação (61.16%). A combinação representa 2.03% da amostra e possui lift 2.40, logo ocorre acima do que seria esperado pela frequência geral do consequente.
18	{genero_crime, periodo_2000_2009} → {genero_suspense}	Que padrão foi encontrado entre gênero crime e lançamento entre 2000 e 2009 e gênero suspense?	Entre os 198 filmes com gênero crime e lançamento entre 2000 e 2009, 114 também apresentam gênero suspense (57.58%). A combinação representa 3.12% da amostra e possui lift 2.36, logo ocorre acima do que seria esperado pela frequência geral do consequente.
19	{avaliacao_media, genero_terror} → {genero_suspense}	Que padrão foi encontrado entre avaliação média intermediária (de 3,0 a menos de 4,0) e gênero terror e gênero suspense?	Entre os 154 filmes com avaliação média intermediária (de 3,0 a menos de 4,0) e gênero terror, 87 também apresentam gênero suspense (56.49%). A combinação representa 2.38% da amostra e possui lift 2.32, logo ocorre acima do que seria esperado pela frequência geral do consequente.
20	{genero_crime, periodo_1990_1999} → {genero_suspense}	Que padrão foi encontrado entre gênero crime e lançamento entre 1990 e 1999 e gênero suspense?	Entre os 153 filmes com gênero crime e lançamento entre 1990 e 1999, 86 também apresentam gênero suspense (56.21%). A combinação representa 2.36% da amostra e possui lift 2.30, logo ocorre acima do que seria esperado pela frequência geral do consequente.
21	{avaliacao_media, genero_crime} → {genero_suspense}	Que padrão foi encontrado entre avaliação média intermediária (de 3,0 a menos de 4,0) e gênero crime e gênero suspense?	Entre os 347 filmes com avaliação média intermediária (de 3,0 a menos de 4,0) e gênero crime, 191 também apresentam gênero suspense (55.04%). A combinação representa 5.23% da amostra e possui lift 2.26, logo ocorre acima do que seria esperado pela frequência geral do consequente.
22	{genero_crime, genero_drama} → {genero_suspense}	Que padrão foi encontrado entre gênero crime e gênero drama e gênero suspense?	Entre os 269 filmes com gênero crime e gênero drama, 148 também apresentam gênero suspense (55.02%). A combinação representa 4.06% da amostra e possui lift 2.26, logo ocorre acima do que seria esperado pela frequência geral do consequente.

Continua na próxima página

Tabela 21 – continuação

Nº	Regra	Pergunta	Resposta
23	{genero_ficcao_cientifica} → {genero_acao}	Que padrão foi encontrado entre gênero ficção científica e gênero ação?	Entre os 486 filmes com gênero ficção científica, 278 também apresentam gênero ação (57.20%). A combinação representa 7.62% da amostra e possui lift 2.25, logo ocorre acima do que seria esperado pela frequência geral do consequente.
24	{avaliacao_baixa, genero_romance} → {genero_comedia}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e gênero romance e gênero comédia?	Entre os 133 filmes com avaliação média baixa (menor que 3,0) e gênero romance, 90 também apresentam gênero comédia (67.67%). A combinação representa 2.47% da amostra e possui lift 1.67, logo ocorre acima do que seria esperado pela frequência geral do consequente.
25	{avaliacao_alta, popularidade_media} → {genero_drama}	Que padrão foi encontrado entre avaliação média alta (igual ou superior a 4,0) e popularidade intermediária (10 a 49 avaliações) e gênero drama?	Entre os 190 filmes com avaliação média alta (igual ou superior a 4,0) e popularidade intermediária (10 a 49 avaliações), 136 também apresentam gênero drama (71.58%). A combinação representa 3.73% da amostra e possui lift 1.64, logo ocorre acima do que seria esperado pela frequência geral do consequente.
26	{avaliacao_alta} → {genero_drama}	Que padrão foi encontrado entre avaliação média alta (igual ou superior a 4,0) e gênero drama?	Entre os 440 filmes com avaliação média alta (igual ou superior a 4,0), 290 também apresentam gênero drama (65.91%). A combinação representa 7.95% da amostra e possui lift 1.51, logo ocorre acima do que seria esperado pela frequência geral do consequente.
27	{avaliacao_baixa, genero_drama} → {popularidade_baixa}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e gênero drama e popularidade baixa (5 a 9 avaliações)?	Entre os 185 filmes com avaliação média baixa (menor que 3,0) e gênero drama, 104 também apresentam popularidade baixa (5 a 9 avaliações) (56.22%). A combinação representa 2.85% da amostra e possui lift 1.49, logo ocorre acima do que seria esperado pela frequência geral do consequente.
28	{avaliacao_baixa, periodo_1970_1989} → {popularidade_baixa}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e lançamento entre 1970 e 1989 e popularidade baixa (5 a 9 avaliações)?	Entre os 137 filmes com avaliação média baixa (menor que 3,0) e lançamento entre 1970 e 1989, 76 também apresentam popularidade baixa (5 a 9 avaliações) (55.47%). A combinação representa 2.08% da amostra e possui lift 1.47, logo ocorre acima do que seria esperado pela frequência geral do consequente.
29	{avaliacao_baixa, genero_comedia} → {popularidade_baixa}	Que padrão foi encontrado entre avaliação média baixa (menor que 3,0) e gênero comédia e popularidade baixa (5 a 9 avaliações)?	Entre os 449 filmes com avaliação média baixa (menor que 3,0) e gênero comédia, 248 também apresentam popularidade baixa (5 a 9 avaliações) (55.23%). A combinação representa 6.80% da amostra e possui lift 1.46, logo ocorre acima do que seria esperado pela frequência geral do consequente.

Continua na próxima página

Tabela 21 – continuação

Nº	Regra	Pergunta	Resposta
30	{genero_ficcao_cientifica, periodo_2010_2018} → {popularidade_media}	Que padrão foi encontrado entre gênero ficção científica e lançamento entre 2010 e 2018 e popularidade intermediária (10 a 49 avaliações)?	Entre os 110 filmes com gênero ficção científica e lançamento entre 2010 e 2018, 73 também apresentam popularidade intermediária (10 a 49 avaliações) (66.36%). A combinação representa 2.00% da amostra e possui lift 1.33, logo ocorre acima do que seria esperado pela frequência geral do consequente.

Fonte: elaboração própria a partir da base *movie_recomm*.

14 Síntese da base *movie_recomm*

As etapas técnicas da base *movie_recomm* foram concluídas. A base foi compreendida, preparada e caracterizada; a unidade transacional foi justificada; o FP-Growth foi executado; regras óbvias, fracas e redundantes foram auditadas; as regras relevantes receberam discussão crítica; e 30 perguntas e respostas foram organizadas em formato tabular.

A análise revelou associações entre gêneros, períodos de lançamento, avaliação média e popularidade. Parte das regras reflete práticas editoriais de classificação, enquanto outras evidenciam concentrações temporais ou combinações de gêneros que ocorrem acima do esperado. Os resultados descrevem padrões de coocorrência do catálogo analisado e não relações de causa e efeito.

15 Comparação entre as bases

Os bancos pertencem a domínios diferentes e exigiram unidades transacionais distintas. Na F1, cada transação representa o resultado de um piloto em uma corrida e combina largada, resultado e equipe. Na base *movie_recomm*, cada transação representa um filme e combina gêneros, período de lançamento, avaliação e popularidade.

Tabela 22 – Comparação dos experimentos de mineração

Experimento	Transações	Itens	Itemsets	Regras iniciais	Parâmetros principais
F1 completa	24.966	27	61	9	Apriori; suporte 2%; confiança 60%
F1, 1950–1959	1.939	13	48	17	Apriori; suporte 2%; confiança 60%
F1, 2014–2024	4.392	17	73	21	Apriori; suporte 2%; confiança 60%
<i>movie_recomm</i>	3.649	31	501	121	FP-Growth; suporte 2%; confiança 55%; lift inicial 1,10

Fonte: elaboração própria.

Em ambos os bancos, variáveis numéricas precisaram ser discretizadas. Na F1, posições e pontos foram convertidos em categorias de desempenho; nos filmes, média, quantidade de avaliações e ano de lançamento foram transformados em faixas. A discretização simplifica os padrões, mas também reduz detalhes e deve ser considerada na interpretação.

O suporte de 2% representa quantidades absolutas muito diferentes: aproximadamente 500 resultados na F1 completa, 39 nos anos 1950, 88 na era híbrida e 73 filmes na base cinematográfica. Portanto, regras com o mesmo suporte percentual não possuem a mesma abrangência absoluta.

A F1 produz regras ligadas à hierarquia esportiva. Muitas são esperadas, como a associação entre largar na frente e vencer, mas os recortes históricos revelam padrões específicos de equipes. A base de filmes produz grande número de combinações entre gêneros e atributos agregados; algumas também são semanticamente óbvias, como relações entre gêneros próximos, exigindo filtragem por lift, redundância e utilidade.

Os principais vieses também diferem. Na F1, mudanças de regulamento, sistemas de pontuação e domínio de equipes afetam a comparabilidade histórica. O agrupamento Equipe_Outras é heterogêneo. Nos filmes, o catálogo é temporalmente desbalanceado, filmes populares recebem mais avaliações e os gêneros são rótulos editoriais que podem ser atribuídos em conjunto.

16 Conclusão

O trabalho cumpriu as etapas de compreensão, preparação, caracterização exploratória, modelagem transacional, extração e análise crítica de regras em dois bancos do Spider 2.0. As análises mostram que a qualidade das regras depende tanto do algoritmo quanto das decisões tomadas antes da mineração.

Na base F1, a separação por períodos permitiu distinguir padrões gerais de associações específicas de cada era. A inclusão do lift revelou que regras com confiança aparentemente alta podem não representar associação positiva quando o consequente é muito frequente. Na base *movie_recomm*, a filtragem de associações óbvias e redundantes produziu um conjunto final mais interpretável.

Ao todo, o relatório apresenta 45 perguntas e respostas: 15 derivadas da base F1 e 30 da base de filmes. Em todos os casos, as interpretações foram tratadas como coocorrências e não como relações causais. A comparação confirma que regras de associação podem ser aplicadas a domínios distintos desde que a unidade transacional seja coerente, os parâmetros sejam justificados e as limitações sejam discutidas.

Referências

AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules. In: *Proceedings of the 20th International Conference on Very Large Data Bases*. [S.l.]: Morgan Kaufmann, 1994. p. 487–499.

HAN, J.; PEI, J.; YIN, Y. Mining frequent patterns without candidate generation. In: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*. [S.l.]: ACM, 2000. p. 1–12.

HARPER, F. M.; KONSTAN, J. A. The movielens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems*, v. 5, n. 4, p. 1–19, 2015.